




## 医学影像分析

### Medical Image Analysis

王宽全  
教授•博士生导师

哈尔滨工业大学•感知计算研究中心•计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 第9章 基于深度学习的医学图像分割方法（一）

### —神经网络与深度学习概述

哈尔滨工业大学•感知计算研究中心•计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 目录

- 深度学习概述
- 深度学习基础网络模型
- 深度学习进阶网络模型


哈尔滨工业大学•感知计算研究中心•计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 深度学习概述

- 深度学习（Deep Learning, DL）是由Hinton等人于2006年提出，是机器学习的一个新领域。
- 深度学习起源于人工神经网络，它的定义：通过组合低层特征形成更加抽象的高层特征，从而从大量的输入数据中学习有效的特征表示，并且将这些特征用于分类、回归和信息检索的一种技术。
- 深度学习被引入机器学习（ML），使其更能接近于最初的目标—人工智能。深度学习是学习样本数据的内在规律和表示层次，这些学习过程中获得的信息对诸如文字，图像和声音数据的解释具有重要作用。

哈尔滨工业大学•感知计算研究中心•计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 深度学习概述



人工智能  
早期的人工智能令人兴奋不已

机器学习  
机器学习开始兴起

深度学习  
深度学习取得突破  
驱动AI蓬勃发展

1950年 1960年 1970年 1980年 1990年 2000年 2010年 2020年

人工智能，机器学习与深度学习的关系

哈尔滨工业大学•感知计算研究中心•计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 目录

- 深度学习概述
- 深度学习基础网络模型
- 深度学习进阶网络模型

哈尔滨工业大学•感知计算研究中心•计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine


## 深度学习基础网络模型

- 前馈神经网络
- 卷积神经网络
- 循环神经网络

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 前馈神经网络

### 1 典型多层神经网络结构



图中每一层由多个神经元组成，各神经元分属不同层，相邻层的单元之间是全连接的，但是同一层之间的单元之间是没有连接的。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 前馈神经网络

### 2 机器学习观点

#### 模型

$$y = f^5(f^4(f^3(f^2(f^1(x)))))$$

#### 学习准则

$$L(y, y')$$

#### 优化

##### 梯度下降

$$\frac{\partial L(y, y')}{\partial f^1} = \frac{\partial f^2}{\partial f^1} \times \frac{\partial f^3}{\partial f^2} \times \frac{\partial f^4}{\partial f^3} \times \frac{\partial f^5}{\partial f^4} \times \frac{\partial L(y, y')}{\partial f^5}$$

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 前馈神经网络

### 3 计算图与自动微分

$$\text{复合函数 } f(x; w, b) = \sigma(wx + b) = 1 / (1 + \exp(-(wx + b)))$$

6个基本函数及其倒数。


函数	导数	
$h_1 = x \times w$	$\frac{\partial h_1}{\partial w} = x$	$\frac{\partial h_1}{\partial x} = w$
$h_2 = h_1 + b$	$\frac{\partial h_2}{\partial h_1} = 1$	$\frac{\partial h_2}{\partial b} = 1$
$h_3 = h_2 \times -1$	$\frac{\partial h_3}{\partial h_2} = -1$	
$h_4 = \exp(h_3)$	$\frac{\partial h_4}{\partial h_3} = \exp(h_3)$	
$h_5 = h_4 + 1$	$\frac{\partial h_5}{\partial h_4} = 1$	
$h_6 = 1/h_5$	$\frac{\partial h_6}{\partial h_5} = -\frac{1}{h_5^2}$	

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 前馈神经网络

### 3 计算图与自动微分

#### 复合函数 $f(x; w, b) = \sigma(wx + b)$ 的计算图




$$\text{链式法则} \quad \frac{\partial f(x; w, b)}{\partial w} = \frac{\partial f(x; w, b)}{\partial h_6} \frac{\partial h_6}{\partial h_5} \frac{\partial h_5}{\partial h_4} \frac{\partial h_4}{\partial h_3} \frac{\partial h_3}{\partial h_2} \frac{\partial h_2}{\partial h_1} \frac{\partial h_1}{\partial w}$$

通过链式法则传播梯度，然后通过梯度下降策略获得最优解。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

### 1. 产生背景




前馈神经网络输入：需要将图像展开成向量输入网络中，空间位置信息被破坏！

卷积神经网络输入：直接以图像作为输入，可以保存空间位置信息。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

### 2. 典型卷积神经网络结构




一个典型的卷积神经网络包括卷积层和池化层（降采样层）然后加上一个和传统多层神经网络一样的一个全连接层。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

### 3. 卷积操作



二维卷积：对图像和滤波矩阵（一组固定的权重：因为每个神经元的权重固定，所以又可以看做一个恒定的滤波器filter）做内积（逐个元素相乘再求和）


哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

### 3. 卷积操作

#### 卷积操作前后尺寸变化


设输入维度为 $i$ ，填充数量为 $p$ ，滤波器大小为 $k$ ，卷积步长为 $s$ ，则卷积后维度为（以一个维度为例，其他维度同理）：



哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

### 3. 卷积操作



哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

### 4. 转置卷积

卷积操作一般情况下会减小被卷积对象的分辨率，那么如果我们想要增大分辨率怎么办呢？



1. 常用的插值方法实现
2. 从卷积的逆过程考虑--转置卷积

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

### 4. 转置卷积

#### 卷积操作的矩阵形式

设被卷积对象为 $X$ 为 $4*4$ 矩阵，滤波器为 $3*3$ 的 $W_{i,j}$ ，步长为1，卷积后的值为 $Y$ 为 $2*2$ ，将卷积核写成如下稀疏矩阵形式：

$$C = \begin{pmatrix} w_{0,0} & w_{0,1} & w_{0,2} & 0 & w_{1,0} & w_{1,1} & w_{1,2} & 0 & w_{2,0} & w_{2,1} & w_{2,2} & 0 & 0 & 0 & 0 & 0 \\ 0 & w_{0,0} & w_{0,1} & w_{0,2} & 0 & w_{1,0} & w_{1,1} & w_{1,2} & 0 & w_{2,0} & w_{2,1} & w_{2,2} & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & w_{0,0} & w_{0,1} & w_{0,2} & 0 & w_{1,0} & w_{1,1} & w_{1,2} & 0 & w_{2,0} & w_{2,1} & w_{2,2} & 0 \\ 0 & 0 & 0 & 0 & 0 & w_{0,0} & w_{0,1} & w_{0,2} & 0 & w_{1,0} & w_{1,1} & w_{1,2} & 0 & w_{2,0} & w_{2,1} & w_{2,2} \end{pmatrix}$$

由于卷积是线性操作，通过将输入 $X$ 转化为列向量表示，可得到其等价矩阵表示：

$$Y = CX$$

Eg: 对矩阵相乘来说，先把 $X$ 转为 $16*1$ 向量，左乘 $C(4*16)$ 即可得到一个 $4*1$ 的向量，然后将其重排列成 $2*2$ 即可得到等价卷积结果。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

## 4. 转置卷积 卷积操作逆过程（不等价于逆！）

$$Y=CX$$



$$X=C^{-1}Y \quad \text{完全恢复数值, } C \text{ 不可逆, 故行不通。}$$

$$X=C^TY \quad \text{不能恢复数值, 能恢复尺寸}$$

“转置”卷积

以之前例子说明：  
 $C^T$  为  $16*4$ ,  $Y$  为  $4*1$ ,  
 可得到  $X$  为  $16*1$  向量,  
 最后将其重排列成  
 $4*4$  即可得到卷积之  
 前的大小。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
 HIT • Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

## 4. 转置卷积


## 转置卷积的实现形式

1. 最简单的方法, 如果想要对某个特征做转置卷积, 可以想象该特征是某个正向卷积的结果, 该卷积的输出即为转置卷积的结果。
2. 利用卷积操作实现转置卷积 (首先对原始特征填充0, 然后做卷积)

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
 HIT • Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

## 4. 转置卷积



转置卷积示例

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
 HIT • Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

## 4. 转置卷积

## 转置卷积操作前后尺寸变化

设输入维度为  $i$ , 填充数量为  $p$ , 滤波器大小为  $k$ , 卷积步长为  $s$ , 则卷积后维度为 (以一个维度为例, 其他维度同理):

$$\text{卷积: } o = \left\lfloor \frac{i + 2p - k}{s} \right\rfloor + 1.$$

反过程  $o=i', i=o'$ 

$$\text{转置卷积: } o' = s(i' - 1) + k - 2p.$$

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
 HIT • Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

## 4. 转置卷积

## 转置卷积参数确定

**正向卷积:** 输入维度为  $i$ , 填充数量为  $p$ , 滤波器大小为  $k$ , 卷积步长为  $s$   
**转置卷积:** 输入维度为  $i'$ , 填充数量为  $p'$ , 滤波器大小为  $k'$ , 卷积步长为  $s'$

**滤波器大小:**  $k'=k$

**步长:** 对于正向卷积  $s=1$  的情况,  $s'=1$ ; 对于正向卷积  $s$  大于1的情况, 其实  $s'$  因该要小于1, 而实际通过在输入中每个元素之间插入  $s-1$  个0, 达到利用  $s'=1$  实现  $s'<1$  的情况!


**零填充:**  $p'=k-1-p$  当正向卷积无填充时, 即  $p=0$  时,  $p'=k-1$ 。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
 HIT • Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

## 4. 转置卷积

## 零填充的解释




当正向卷积无填充时, 即  $p=0$  时,  $p'=k-1$ 。转置卷积输出 (绿色) 中左上角点只是与输入中左上角点有联系 (考虑正向卷积), 从而当  $p'=k-1$  可实现上述规则! 而对于正向卷积有填充的情况, 比较好理解, 我们实际需要的是对真实点的影响, 应该先把无用的0填充点去掉!

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
 HIT • Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

## 4. 转置卷积

## 转置卷积操作示例




卷积 ( $i=4, p=0, k=3, s=1$ ) 等价转置卷积 ( $i'=2, p'=2, k'=k, s'=1$ )

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

## 4. 转置卷积

## 转置卷积操作示例



卷积 ( $i=5, p=1, k=3, s=2$ ) 等价转置卷积 ( $i'=3, p'=1, k'=k, s'=1$ )

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

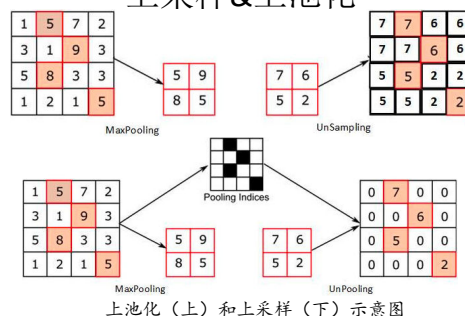
## 4. 转置卷积

## 转置卷积的意义：

- 虽然不能像反卷积一样完全恢复卷积之前的信号，但是可以恢复之前的特征维度
- 根据零填充可以恢复卷积前后像素对应关系，后续可通过学习滤波器参数，逼近之前真实的信号！

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 上采样&amp;上池化




上池化（上）和上采样（下）示意图

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

## 5. 卷积作为特征提取器



哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

## 6. 卷积层

卷积层的作用主要是利用可学习的核 $k_{ij}^{(l)}$ 在输入的特征图的不同位置检测局部特征，底层卷积层可能只能提取一些低级的特征如边缘、线条和角等，更高层的卷积层能从低级特征中迭代提取更复杂的特征。特别的，卷积层 $L$ 的单元仅仅依赖于其前一层 $L-1$ 层的特征图的一个空间连续的子集，并通过与卷积核 $k_{ij}^{(l)}$ 做卷积操作计算得到其激活值：

$$A_j^{(l)} = f \left( \sum_{i=1}^{M^{(l-1)}} A_i^{(l-1)} * k_{ij}^{(l)} + b_j^{(l)} \right) \quad (1.12)$$

其中 $M^{(l-1)}$ 表示 $L-1$ 层中特征图的数量， $*$ 表示卷积操作， $b_j^{(l)}$ 是一个偏置项， $f(\cdot)$ 是一个非线性激活函数。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine






## 卷积神经网络

## 8. 深度卷积神经网络模型--经典分类框架

## GoogLeNet--Inception 模块



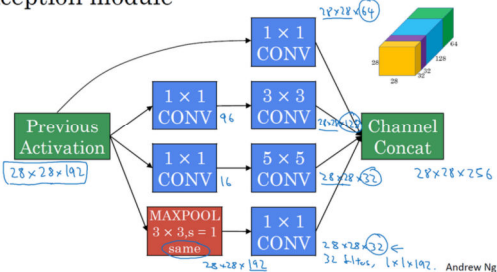
贡献:

- 从传统的一味增加“深度”扩展为增加“宽度”。缓解了由于深度增加导致的参数数量暴增问题。
- 通过拼接经过多种卷积核的特征, 实现多尺度特征融合。
- 1\*1卷积降低特征层的通道数量, 进一步降低参数

哈尔滨工业大学·感知计算研究中心·计算医学课题组

HIT •Computational Perception Center • Research Group of Computing Medicine

## Inception module




哈尔滨工业大学·感知计算研究中心·计算医学课题组

HIT •Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

## 8. 深度卷积神经网络模型--经典分类框架

## ResNet



ILSVRC-2015的冠军。该网络采用了152层的网络结构,

贡献: 网络通过引入了残差块解决了训练非常深的深度学习网络框架时的“退化问题”。


哈尔滨工业大学·感知计算研究中心·计算医学课题组

HIT •Computational Perception Center • Research Group of Computing Medicine

## 卷积神经网络

## 8. 深度卷积神经网络模型--经典分类框架

## ResNet--残差块




残差块通过在网络中加入一个恒等的“跳跃连接”使得网络层能够复制其输入到网络的下一层。

哈尔滨工业大学·感知计算研究中心·计算医学课题组

HIT •Computational Perception Center • Research Group of Computing Medicine

## Residual block



哈尔滨工业大学·感知计算研究中心·计算医学课题组

HIT •Computational Perception Center • Research Group of Computing Medicine

## 循环神经网络

## 1 产生背景--前馈神经网络的不足

- ▶ 连接存在层与层之间, 每层的节点之间是无连接的。  
(无循环)
- ▶ 输入和输出的维数都是固定的, 不能任意改变。无法处理变长的序列数据。
- ▶ 假设每次输入都是独立的, 也就是说每次网络的输出只依赖于当前的输入。

哈尔滨工业大学·感知计算研究中心·计算医学课题组

HIT •Computational Perception Center • Research Group of Computing Medicine

## 循环神经网络

### 2 循环神经网络概述

- 循环神经网络通过使用带自反馈的神经元，能够处理任意长度的序列。
- 循环神经网络比前馈神经网络更加符合生物神经网络的结构。
- 循环神经网络已经被广泛应用在语音识别、语言模型以及自然语言生成等任务上。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 循环神经网络

给定一个输入序列  $\mathbf{x}_{1:T} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_t, \dots, \mathbf{x}_T)$ ，循环神经网络通过下面公式更新带反馈边的隐藏层的活性值  $\mathbf{h}_t$ ：

$$\mathbf{h}_t = \begin{cases} 0 & t = 0 \\ f(\mathbf{h}_{t-1}, \mathbf{x}_t) & \text{otherwise} \end{cases}$$


其中延迟器为一个虚拟单元，记录神经元最近一次活性值。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 循环神经网络

### 3. 经典RNN框架

$$\mathbf{h}_t = f(U\mathbf{h}_{t-1} + W\mathbf{x}_t + \mathbf{b}),$$



RNN状态更新过程

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 循环神经网络

### 4. 循环神经网络面临的问题


- ▶ 循环神经网络在时间维度上非常深！
- ▶ 梯度消失或梯度爆炸
- ▶ 长期依赖问题
- ▶ 如何改进？
- ▶ 梯度爆炸问题
- ▶ 权重衰减
- ▶ 梯度截断
- ▶ 梯度消失问题与长期依赖问题
- ▶ 改进模型--LSTM

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 循环神经网络

### 5. LSTM 框架

LSTM总体结构




LSTM主要由四个部分组成，包括记忆细胞的更新与三个门控单元：遗忘门，输入门与输出门。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 循环神经网络

### 5. LSTM 框架

记忆细胞



为了解决长期依赖问题，LSTM引入记忆细胞模块，从图中可以看出，该模块具有很少分支，序列传播过程中， $C_t$ 变化很慢，可有效保存上一阶段信息。


哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine



## 循环神经网络

### 5. LSTM 框架

记忆信息微调：门控信号




当然， $C_t$ 虽然变化很慢，但不是一成不变的，LSTM通过利用门结构对细胞状态进行删除或添加，如右图所示，利用一个sigmoid函数与矩阵乘法可实现，因为sigmoid函数输出0-1，代表流过sigmoid的信息，0表示不通过，1表示全通过。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 循环神经网络

### 5. LSTM 框架

遗忘门



$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$


首先确定细胞状态需要丢弃哪些信息。这部分操作是通过一个称为遗忘门的sigmoid单元来实现的。它通过综合上个状态 $h_{t-1}$ 和当前输入 $x_t$ 信息来输出一个0-1之间的向量，该向量里面的0-1值表示细胞状态 $C_{t-1}$ 中的哪些信息保留或丢弃多少。0表示不保留，1表示都保留。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 循环神经网络

### 5. LSTM 框架

输入门



$$\begin{aligned} i_t &= \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \\ \tilde{C}_t &= \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \end{aligned}$$


然后确定细胞状态需要增加哪些信息。这一步又分为两个步骤，  
(1) 利用 $h_{t-1}$ 和 $x_t$ 通过输入门的sigmoid操作来决定更新哪些信息。  
(2) 利用 $h_{t-1}$ 和 $x_t$ 通过一个tanh层得到新的候选细胞信息 $\tilde{C}_t$ ，这些信息可能会被更新到细胞信息中。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 循环神经网络

### 5. LSTM 框架

记忆细胞更新



$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$


更新旧细胞信息 $C_{t-1}$ 为新细胞信息 $C_t$ 。更新规则：通过遗忘门选择忘记旧细胞信息的一部分，通过输入门选择添加候选细胞信息 $\tilde{C}_t$ 的一部分得到新的细胞信息。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 循环神经网络

### 5. LSTM 框架

输出门




$$\begin{aligned} o_t &= \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \\ h_t &= o_t * \tanh(C_t) \end{aligned}$$

更新完细胞状态后需要根据输入的 $h_{t-1}$ 和 $x_t$ 来判断输出细胞的哪些状态特征，分为两个部分：  
(1) 将输入经过输出门的sigmoid层得到判断条件，  
(2) 将细胞状态经过tanh层得到一个1-1之间的向量，该向量与输出门得到的判断条件相乘就得到了最终该LSTM单元输出。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 生成对抗网络



哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 目录

- 深度学习概述
- 深度学习基础网络模型
- 深度学习进阶网络模型

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 深度学习进阶网络模型

- 概率图模型
- 玻尔兹曼机模型
- 深度置信网络模型
- 深度生成模型
- 深度强化学习

上述深度学习模型在医学图像分割任务中并不常用，此部分内容可课后自行阅读，本课程不作展开！

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

深度学习的概述结束！

基于深度学习的医学图像分割是接下来的主要内容！

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 第9章 基于深度学习的医学图像分割方法（二）

—深度学习图像分割方法

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 目录

- 医学图像分割预处理
- 医学图像分割方法

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 医学图像分割预处理

### 1 CT图像窗宽窗位校正

#### 背景

- CT图像Hu值：表示CT图像强度值，每个点的强度值衡量了X射线经过该处人体组织后的衰减率。
- 对于人体组织而言，Hu值的范围为-1000-1000之间，而人眼灰度分辨率大约16个灰阶。
- 人眼可分辨CT值为 $2000/16=125Hu(2000/16)$ ，也就是说CT值相差125Hu，人眼才能分辨出差别。


哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 医学图像分割预处理

### 1 CT图像窗宽窗位校正

#### 窗宽窗位


- 窗位：在整个CT值范围内某一选定位置，图像显示以该CT值为中心；
- 窗宽：选定的CT值显示范围；
- 调节之后的CT值范围： $[\text{窗位}-\text{窗宽}/2 \sim \text{窗位}+\text{窗宽}/2]$



哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 医学图像分割预处理

### 1 CT图像窗宽窗位校正




灰度图像常采用8位存储，故最后需要将Hu值映射到0-255范围用于显示图像！

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 医学图像分割预处理

### 1 CT图像窗宽窗位校正


#### 窗宽窗位校正前后对比图



哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 医学图像分割预处理

### 2 图像强度归一化：零均值和归一化方差



- 零均值的主要是对于数据中的每个独立的特征进行逐特征减均值的操作，其几何解释可认为是将数据沿着每个维度绕原点居中，如图b所示。
- 归一化方差主要是对于每一个特征维度进行归一化操作，使得数据在每一个维度具有大致相同的尺度，如图c所示。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 目录

- 医学图像分割预处理
- 医学图像分割方法

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 医学图像分割方法

### 经典深度学习图像分割方法

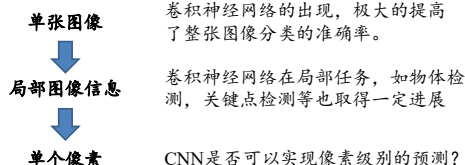
- 2014年加州大学伯克利分校Long等人提出的FCN网络首次利用卷积神经网络实现了逐像素的稠密预测，是深度学习分割网络的开山之作。
- 2015年德国弗赖堡大学Ronneberger等人提出的U-Net网络改进了FCN网络，该网络提出的编解码结构作为后续分割网络最常用的分割网络框架。
- 2016年慕尼黑工业大学Milletari等人为了扩展U-Net网络，首次提出了V-Net，该网络能够直接处理3维体数据。
- 2017年香港大学Zhao等人为了充分利用分割网络中全局特征与局部特征，提出了PSP-Net网络，该网络可利用金字塔池化模块提高获取全局信息的能力。
- 2018年亚利桑那州立大学Zhou等人为了改进U-Net网络的跳跃连接并充分利用网络浅层特征，提出了U-Net++网络。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 1 FCN网络 (2014)

#### 产生背景



哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 1 FCN网络

#### 像素级别的预测—图像的语义分割

#### 1 传统CNN进行语义分割的方法：

将像素周围一个小区域作为CNN输入，做训练和预测，将其视为图像分类任务，进而将该类别作为中心像素的类别。

#### 2 传统CNN语义分割方法存在的问题：


- 存储开销大
- 计算效率低下，过多的重复计算
- 如何来确定区域大小，小区域限制感知区域，大区域计算开销大

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 1 FCN网络

#### FCN网络结构对CNN的改进



哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 全卷积神经网络

与传统的卷积神经网络相比，全卷积神经网络的三个特点：


1. 不含全连接层的全卷积网络，可以适应任意尺寸的网络输入；
2. 利用反卷积（Deconvolution）操作，增大输出数据的尺寸；
3. 结合不同深度的跳连接（Skip connection）进行数据融合（Fusion）。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 1 FCN网络

#### FCN网络稠密预测



将全连接层卷积化之后，网络全部变为卷积操作，通过对最后一个卷积层的特征图进行上采样，使它恢复到输入图像相同的尺寸，从而可以对每一个像素都产生一个预测，即从图像级别的分类延伸到像素级别的分类。


哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 1 FCN网络

#### 上采样方法

1. 插值法上采样（实质图像resize）
2. 转置卷积上采样




哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法


### 1 FCN网络

#### 全局与局部信息融合



FCN网络通过跳跃连接，通过叠加不同层的特征图，巧妙的融合全局信息与局部信息，试图解决语义分割面临的关于语义和定位的矛盾。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine



FCN是深度学习在图像分割的开山之作，FCN优点是实现端到端分割等，缺点是分割结果细节不够好，可以看到图四，FCN8s是上面讲的pool4、pool3和特征map融合，FCN16s是pool4和特征map融合，FCN32s是只有特征map，得出结果都是细节不够好，具体可以看自行车。由于网络中只有卷积没有全连接，所以这个网络又叫全卷积网络。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 1 FCN网络

#### FCN网络的特点

- 全连接层改为卷积层形成全卷积网络，使得网络能够适应不同大小的输入；
- 为了实现稠密预测，网络中利用不同的中间层的上采样（实际使用双线性插值或转置卷积实现）实现将特征的分辨率恢复到原始图像大小。
- 通过“跳跃连接”的方法将深层的、粗糙的语义信息与浅层的、精细的位置信息融合起来，充分利用了语义和定位信息。


哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 2 U-Net网络 (2015)

#### 编码

#### 解码




哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 2 U-Net网络

#### Overlap-tile 策略



- 细胞电镜图像分辨率很大，直接输出GPU显存不够，因此需要分块输入最后拼接。
- 为了解决分块导致的边缘分割效果不好，取预测块区域（黄色框）稍大的区域作为输入（蓝色框）进行预测。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 2 U-Net网络

#### U-Net网络较FCN的改进

- FCN上采样时是单通道的，而U-Net上采样层保留了多通道的信息，这使得网络能够传递语义信息到更高的分辨率层。
- 网络使用了相同数量的上采样和下采样层，同时对于数据融合方式而言，U-Net采用通道拼接方式，而FCN是直接相加。
- 通过图像扩增解决医学图像数量少的问题：通过伸缩变形等图像扩增手段，网络可以学习到不同尺度不同形状的特征。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT • Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 3 V-Net网络 (2016)

#### 背景

- FCN与U-Net等网络输入为2维图像，不能直接处理3维数据
- 医学图像数据一般是体数据，包含三个维度。

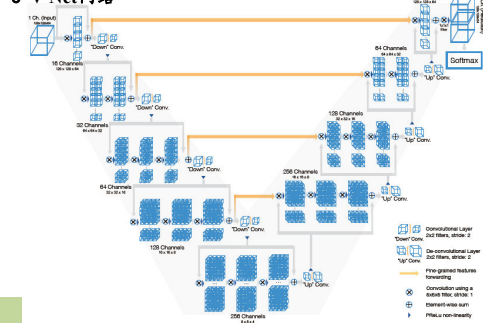


V-Net网络结构与U-Net基本相同，只是将U-Net中的2D卷积、2D转置卷积操作分别替换相应的3D形式，同时池化层由3D卷积替代。该网络可以直接输入3D医学体数据，直接得到3D稠密预测的分割结果。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 3 V-Net网络



HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 3 V-Net网络

#### V-Net网络特点

V-Net可直接处理3D医学体数据：

- 为了加快网络的学习同时减少过拟合的出现，V-Net在每一个卷积模块中引入了残差模块。
- 相比于3D U-Net，该网络中没有池化层，下采样过程由相应的卷积层替代，这种替代的好处在于训练的时候占据更小的内存。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 4 PSPNet网络 (2017)

#### 背景


- 分割任务中，许多标签之间存在关联，这种关联性特征十分重要。而FCN等网络不能捕捉这些关联。
- FCN等模型会忽略小尺寸的内容，而大尺寸内容可能会超过FCN网络接收范围，从而导致不连续的预测。
- FCN不能有效利用全局信息

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 4 PSPNet网络

#### PSPNet网络结构



金字塔池化模块融合四种尺度的特征，充分利用了全局信息。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 5 U-Net++网络 (2018)

#### 背景

- 当前的分割网络基本都采用了降采样，上采样与跳层的结构范式。
- 对于特征提取阶段，浅层结构可以抓取图像的一些简单的特征，比如边界，颜色，而深层结构能抓取到图像抽象语义特征。
- U-Net从第四层之后才上采样，这样其实只是抓取了深层的特征，没有充分利用浅层信息。


哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine



## 基于卷积神经网络的分割方法

### 5 U-Net++网络

#### 背景



Why up-sampling until 4 level?


传统的U-Net在第四层之后进行上采样，为什么不从其他层？

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 5 U-Net++网络

#### 不同层次上采样的U-Net网络




既然不知道从哪层开始上采样，那么可以有上述几种可能性，通过在不同层次进行上采样，可以训练抓取不同层次特征的U-Net网络（数量太多），是否有更优方案？

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 5 U-Net++网络

#### U-Net网络的集成




上述网络的四个子集分别为不同深度上采样的U-Net框架，但该网络存在问题：反向传播对右图红色部分无法更新梯度！

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 5 U-Net++网络



解决梯度更新问题：


- (1) 将原始的U-Net中的长连接改为短连接
- (2) 在子网络的输出位置加入深度监督

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 5 U-Net++网络

#### U-Net++网络结构




在上面的基础上，加上原始U-Net网络中的长连接，形成长短连接并存的状态，即为U-Net++网络。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于卷积神经网络的分割方法

### 5 U-Net++网络

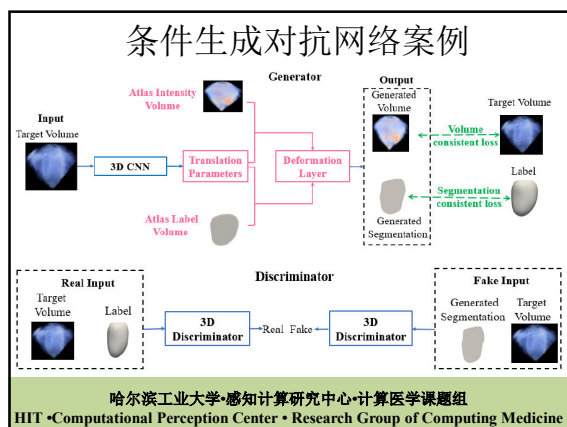
#### U-Net++测试时剪枝



由于深度监督的存在，每一个子网络测试时可输出分割结果，如果子网络输出足够好，可以剪去其他多余的部分，简化网络。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine





## 总结

- 全卷积网络是基于深度学习的分割方法的主流。原理简单，分割性能也得到了业界的广泛认可！
- 其他形式的深度学习分割算法，例如LSTM作为课下作业，大家自己学习！

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于循环神经网络的分割方法

### 1 CNN+BDCLSTM


- 医学图像与自然图像不同，一般是体数据的形式，存在三个维度 (H,W,D)
- 直接逐切片分割，利用二维图像分割方法会丧失层间上下文信息，直接输入3D数据，显存消耗过大。
- 通过将体数据的每个切片当作一个序列数据，将其输入循环神经网络中可以使网络感知层间信息，得到更好的分割结果。

Chen J, Yang L, Zhang Y, et al. Combining fully convolutional and recurrent neural networks for 3d biomedical image segmentation[C]//Advances in neural information processing systems. 2016: 3036-3044.

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于循环神经网络的分割案例

### 1 CNN+BDC-LSTM




哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于循环神经网络的分割方法

### 1 CNN+BDC-LSTM

#### 双向卷积 LSTM模块 (BDC-LSTM)




哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine

## 基于循环神经网络的分割方法

### 1 CNN+BDC-LSTM

#### 卷积LSTM (CLSTM)



CLSTM模块是LSTM在二维图像域的扩展，主要变化为：  
1. CLSTM输入为二维图像数据，而LSTM为向量数据。  
2. LSTM门更新公式中的向量乘积在CLSTM中改为卷积操作。

哈尔滨工业大学·感知计算研究中心·计算医学课题组  
HIT •Computational Perception Center • Research Group of Computing Medicine