

基于核函数的方法

刘家锋

哈尔滨工业大学

基于核函数的方法

- 1 再生核空间
- 2 基于核的主成分分析

◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

核函数


- 核函数的应用
 - 核函数是模式识别中常用的一种
 - 应用核函数可以很容易地使用线性方法解决非线性问题
 - 几乎所有线性的流形学习方法都有对应的“核化”版本，如KPCA，KLDA，KICA等等

核函数

● 核机制 (Kernel Trick)

- $\phi(\mathbf{x}) : \mathcal{X} \rightarrow \mathcal{Z}$, 将低维空间 \mathcal{X} 中的矢量 \mathbf{x} 映射为高维空间 \mathcal{Z} 中的矢量 \mathbf{z}
- 高维空间中的矢量内积可以由低维空间的**核函数**计算:

$$\kappa(\mathbf{x}_1, \mathbf{x}_2) = \langle \mathbf{z}_1, \mathbf{z}_2 \rangle = \langle \phi(\mathbf{x}_1), \phi(\mathbf{x}_2) \rangle$$



核函数用于SVM

- 线性SVM

优化目标:

$$L(\boldsymbol{\alpha}) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j z_i z_j \mathbf{y}_i^t \mathbf{y}_j$$

判别函数:

$$g(\mathbf{x}) = \sum_{i=1}^n \alpha_i z_i \mathbf{y}_i^t \mathbf{x} + b$$

核函数用于SVM

- 非线性SVM

优化目标:

$$L(\boldsymbol{\alpha}) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j z_i z_j \kappa(\mathbf{y}_i, \mathbf{y}_j)$$

判别函数:

$$g(\mathbf{x}) = \sum_{i=1}^n \alpha_i z_i \kappa(\mathbf{y}_i, \mathbf{x}) + b$$

核函数的数学基础

● 再生核希尔伯特空间

- 核函数的数学基础来自于泛函中的再生核空间理论（RKHS, Reproducing Kernel Hilbert Space）
- RKHS本质上是一个函数空间
- 使用核函数时不需要显示地定义非线性映射 $\phi(\mathbf{x}) : \mathcal{X} \rightarrow \mathcal{Z}$, 但这个映射是存在的
- 核函数将输入空间 \mathcal{X} 映射到了一个什么样的空间 \mathcal{Z} ?

核函数的数学基础

- 内积空间和Hilbert空间

- 内积空间：在矢量空间 \mathcal{X} 上，如果可以定义一个对称的双线性函数，满足

$$\langle \mathbf{x}, \mathbf{x} \rangle \geq 0, \quad \forall \mathbf{x} \in \mathcal{X}$$

则称 \mathcal{X} 为一个内积空间

- Hilbert空间：具有可分性和完备性的内积空间

核函数的数学基础

- 平方可积的函数空间

令 $X \subseteq R^d$, 平方可积函数空间定义为:

$$\mathcal{F} = L_2(X) = \left\{ f : \int_X f^2(\mathbf{x}) d\mathbf{x} < \infty \right\}$$

定义内积:

$$\langle f, g \rangle = \int_X f(\mathbf{x}) g(\mathbf{x}) d\mathbf{x}$$

可以证明, 平方可积的函数空间是一个Hilbert空间

核函数的数学基础

- 半正定矩阵

- 半正定矩阵：如果矩阵 $\mathbf{M} \in R^{d \times d}$ 满足

$$\mathbf{x}^t \mathbf{M} \mathbf{x} \geq 0, \quad \forall \mathbf{x} \in R^d$$

称为半正定矩阵

- 半正定矩阵的行列式值： $|\mathbf{M}| \geq 0$
- 半正定矩阵的特征值： $\{\lambda_i \geq 0\}_{i=1, \dots, d}$

- Gram矩阵：

- 矢量集 $S = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ 的Gram矩阵定义为 $\mathbf{G}_{ij} = \langle \mathbf{x}_i, \mathbf{x}_j \rangle$
- Gram矩阵是一个实对称矩阵，因此是半正定矩阵

核函数的数学基础

- 有限半正定函数 (Finitely positive semi-definite functions)
 - 如果函数 $\kappa: \mathcal{X} \times \mathcal{X} \rightarrow R$ 是对称函数
 - 对于 \mathcal{X} 的任意有限子集 $S = \{\mathbf{x}_1, \dots, \mathbf{x}_n\} \subset \mathcal{X}$ 构成的矩阵 \mathbf{K} 为半正定矩阵, $\mathbf{K}_{ij} = \kappa(\mathbf{x}_i, \mathbf{x}_j)$
 - 函数 $\kappa(\cdot, \cdot)$ 称为有限半正定函数

核函数的数学基础

- Mercer定理

令 $\kappa: \mathcal{X} \times \mathcal{X} \rightarrow R$ 为连续函数，当且仅当 $\kappa(\cdot, \cdot)$ 为有限半正定函数时，存在矢量空间 \mathcal{X} 到Hilbert空间 \mathcal{F} 上的映射 $\phi: \mathcal{X} \rightarrow \mathcal{F}$ ，满足：

$$\kappa(\mathbf{x}, \mathbf{z}) = \langle \phi(\mathbf{x}), \phi(\mathbf{z}) \rangle$$

核函数的数学基础

必要性证明：因为Gram矩阵是半正定矩阵，必要性是显然的。

充分性证明：首先构造一个函数空间

$$\mathcal{F} = \left\{ \sum_{i=1}^n \alpha_i \kappa(\mathbf{x}_i, \cdot) : n \in \mathcal{N}, \mathbf{x}_i \in \mathcal{X}, \alpha_i \in R, i = 1, \dots, n \right\}$$

因为 $\forall f, g \in \mathcal{F}$, $af \in \mathcal{F}$, $(f + g)(\mathbf{x}) = f(\mathbf{x}) + g(\mathbf{x}) \in \mathcal{F}$, 所以 \mathcal{F} 是一个闭集。令 $f(\cdot) = \sum_{i=1}^l \alpha_i \kappa(\mathbf{x}_i, \cdot)$, $g(\cdot) = \sum_{j=1}^n \beta_j \kappa(\mathbf{x}_j, \cdot)$, 定义 \mathcal{F} 上的内积:

$$\langle f, g \rangle = \sum_{i=1}^l \sum_{j=1}^n \alpha_i \beta_j \kappa(\mathbf{x}_i, \mathbf{x}_j) = \sum_{i=1}^l \alpha_i g(\mathbf{x}_i) = \sum_{j=1}^n \beta_j f(\mathbf{x}_j)$$

显然, $\langle f, g \rangle$ 是实对称的双线性函数。由于 $\kappa(\cdot, \cdot)$ 为有限半正定函数, 因此:

$$\langle f, f \rangle = \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j \kappa(\mathbf{x}_i, \mathbf{x}_j) = \boldsymbol{\alpha}^t \mathbf{K} \boldsymbol{\alpha} \geq 0$$

所以对 $\langle f, g \rangle$ 的定义符合内积的要求。可以证明这样定义的函数空间 \mathcal{F} 具有完备性和可分性, 是一个Hilbert空间。

核函数的数学基础

- 再生核空间 (RKHS: Reproducing Kernel Hilbert Space)
 - 由函数 $\kappa(\cdot, \cdot)$ 诱导出的函数空间 \mathcal{F}_κ 具有再生性:

$$\langle f, \kappa(\mathbf{x}, \cdot) \rangle = \sum_{i=1}^l \alpha_i \kappa(\mathbf{x}_i, \mathbf{x}) = f(\mathbf{x})$$

\mathcal{F}_κ 称为再生核空间。

- 核函数 $\kappa(\cdot, \cdot)$ 对应的映射 $\phi: \mathcal{X} \rightarrow \mathcal{F}$ 实际上是:

$$\phi(\mathbf{x}) = \kappa(\mathbf{x}, \cdot) \in \mathcal{F}_\kappa$$

- 根据再生性:

$$\langle \phi(\mathbf{x}), \phi(\mathbf{z}) \rangle = \langle \kappa(\mathbf{x}, \cdot), \kappa(\mathbf{z}, \cdot) \rangle = \kappa(\mathbf{x}, \mathbf{z})$$

核函数的封闭性

- 下列方式得到的函数是核函数

- $\kappa(\mathbf{x}, \mathbf{z}) = \kappa_1(\mathbf{x}, \mathbf{z}) + \kappa_2(\mathbf{x}, \mathbf{z})$, κ_1 和 κ_2 是核函数

- $\kappa(\mathbf{x}, \mathbf{z}) = a\kappa_1(\mathbf{x}, \mathbf{z})$, $a \in R^+$

- $\kappa(\mathbf{x}, \mathbf{z}) = \kappa_1(\mathbf{x}, \mathbf{z})\kappa_2(\mathbf{x}, \mathbf{z})$

- $\kappa(\mathbf{x}, \mathbf{z}) = f(\mathbf{x})f(\mathbf{z})$, $f: \mathcal{X} \rightarrow R$

- $\kappa(\mathbf{x}, \mathbf{z}) = \kappa_3(\phi(\mathbf{x}), \phi(\mathbf{z}))$, $\phi: \mathcal{X} \rightarrow R^D$, κ_3 是 $R^D \times R^D$ 上的核函数

- $\kappa(\mathbf{x}, \mathbf{z}) = \mathbf{x}^t \mathbf{B} \mathbf{z}$, \mathbf{B} 是对称半正定矩阵

- $\kappa(\mathbf{x}, \mathbf{z}) = P(\kappa_1(\mathbf{x}, \mathbf{z}))$, $P(\cdot)$ 是多项式函数

- $\kappa(\mathbf{x}, \mathbf{z}) = \exp(\kappa_1(\mathbf{x}, \mathbf{z}))$

高斯核

可以证明 $\kappa(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\|\mathbf{x}-\mathbf{z}\|^2}{\sigma^2}\right)$ 是核函数

$\langle \mathbf{x}, \mathbf{z} \rangle$ 是核函数, 因此 $\kappa_1(\mathbf{x}, \mathbf{z})$ 和 $\kappa_2(\mathbf{x}, \mathbf{z})$ 是核函数:

$$\kappa_1(\mathbf{x}, \mathbf{z}) = \exp\left(\frac{2\langle \mathbf{x}, \mathbf{z} \rangle}{\sigma^2}\right)$$

$$\kappa_2(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\|\mathbf{x}\|^2}{\sigma^2}\right) \cdot \exp\left(-\frac{\|\mathbf{z}\|^2}{\sigma^2}\right)$$

$\kappa(\mathbf{x}, \mathbf{z})$ 也是核函数:

$$\begin{aligned} \kappa(\mathbf{x}, \mathbf{z}) &= \exp\left(\frac{2\langle \mathbf{x}, \mathbf{z} \rangle}{\sigma^2}\right) \cdot \exp\left(-\frac{\|\mathbf{x}\|^2}{\sigma^2}\right) \cdot \exp\left(-\frac{\|\mathbf{z}\|^2}{\sigma^2}\right) \\ &= \exp\left(\frac{2\langle \mathbf{x}, \mathbf{z} \rangle}{\sigma^2} - \frac{\langle \mathbf{x}, \mathbf{x} \rangle}{\sigma^2} - \frac{\langle \mathbf{z}, \mathbf{z} \rangle}{\sigma^2}\right) \\ &= \exp\left(-\frac{\|\mathbf{x} - \mathbf{z}\|^2}{\sigma^2}\right) \end{aligned}$$

Representer Theorem

- 表示定理

令 \mathcal{X} 为非空集合， κ 为定义在 $\mathcal{X} \times \mathcal{X}$ 上的核函数，相应的再生核空间 \mathcal{H}_κ 。给定单调上升函数 $g: [0, \infty) \rightarrow R$ ，训练样本集

$$(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n) \in \mathcal{X} \times R$$

以及任意的经验风险函数

$$E: (\mathcal{X} \times R^2)^n \rightarrow R \cup \{\infty\}$$

则下列优化问题的解：

$$f^* = \arg \min_{f \in \mathcal{H}_\kappa} \{E[(\mathbf{x}_1, y_1, f(\mathbf{x}_1)), \dots, (\mathbf{x}_n, y_n, f(\mathbf{x}_n))] + g(\|f\|)\}$$

满足：

$$f^*(\cdot) = \sum_{i=1}^n \alpha_i \kappa(\mathbf{x}_i, \cdot)$$

其中， $\alpha_i \in R, i = 1, \dots, n$


A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

线性PCA方法回顾

● 线性PCA的目标

寻找一组新的基矢量 $\{\mathbf{e}_1, \dots, \mathbf{e}_{d'}\}$, 使得样本集 $\{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ 在新的坐标系下表示的误差最小

$$\begin{aligned}\min_{\{\mathbf{e}_i\}} J(\{\mathbf{e}_i\}) &= \frac{1}{n} \sum_{k=1}^n \|\mathbf{x}_k - \hat{\mathbf{x}}_k\|^2 \\ &= \frac{1}{n} \sum_{k=1}^n \sum_{i=d'+1}^d \langle \mathbf{x}_k - \boldsymbol{\mu}, \mathbf{e}_i \rangle^2\end{aligned}$$



线性PCA方法回顾

- 线性PCA的优化解:

- 基矢量 $\{\mathbf{e}_i\}$ 满足:

$$\Sigma \mathbf{e}_i = \lambda_i \mathbf{e}_i$$

其中:

$$\Sigma = \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k - \boldsymbol{\mu})(\mathbf{x}_k - \boldsymbol{\mu})^t$$

- 基矢量 $\{\mathbf{e}_i\}$ 为协方差矩阵 Σ 的特征矢量

核化PCA方法


● KPCA的目标

- 将样本集 $\{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ 映射到再生核空间 \mathcal{F}_k :

$$\{\phi(\mathbf{x}_1), \dots, \phi(\mathbf{x}_n)\}$$

(假设映射之后的样本集均值为0)

- 在 \mathcal{F}_k 中寻找一组新的基矢量 $\{\mathbf{V}_1, \dots, \mathbf{V}_{d'}\}$, 使得样本集在新的坐标系下表示的误差最小
- 计算矢量 $\phi(\mathbf{x})$ 在 $\{\mathbf{V}_1, \dots, \mathbf{V}_{d'}\}$ 上的投影



核化PCA方法

● KPCA的困难

- 协方差矩阵的计算：核函数只能计算映射后矢量的内积，无法计算外积

$$\kappa(\mathbf{x}, \mathbf{y}) = \langle \phi(\mathbf{x}), \phi(\mathbf{y}) \rangle, \quad \Sigma_{\mathcal{F}_\kappa} = \frac{1}{n} \sum_{k=1}^n \phi(\mathbf{x}_k) \phi^t(\mathbf{x}_k)$$

- 特征矢量的计算： $\Sigma_{\mathcal{F}_\kappa}$ 的维数为 ∞
- 基矢量 $\mathbf{V}_i \in \mathcal{F}_\kappa$ 的表示
- $\phi(\mathbf{x})$ 在基矢量上的投影

核化PCA方法

● 基矢量的表示

根据**Mercer** 定理, $\mathbf{V}_i \in \mathcal{F}_\kappa$ 本质上是定义在 \mathcal{X} 上的一个函数(表示为 $f_i(\cdot)$), 存在 $m, \mathbf{y}_1, \dots, \mathbf{y}_m \in \mathcal{X}, \alpha_1, \dots, \alpha_m \in R$ 使得:

$$f_i(\cdot) = \sum_{l=1}^m \alpha_l \kappa(\mathbf{y}_l, \cdot)$$

KPCA的优化目标: (D 为特征空间的维数)

$$\begin{aligned} J(\{\mathbf{V}_i\}) &= \frac{1}{n} \sum_{k=1}^n \sum_{i=d'+1}^D \langle \phi(\mathbf{x}_k), \mathbf{V}_i \rangle^2 \\ &= \frac{1}{n} \sum_{k=1}^n \sum_{i=d'+1}^D \langle \kappa(\mathbf{x}_k, \cdot), f_i(\cdot) \rangle^2 \\ &= \frac{1}{n} \sum_{k=1}^n \sum_{i=d'+1}^D f_i^2(\mathbf{x}_k) \quad (\text{核函数的再生性}) \end{aligned}$$

核化PCA方法

- 基矢量的表示

结合对基矢量 $\{\mathbf{V}_i\}$ 的单位长度约束，可以构造Lagrange函数：

$$L(\{f_i(\cdot)\}) = \frac{1}{n} \sum_{k=1}^n \sum_{i=d'+1}^D f_i^2(\mathbf{x}_k) - \sum_{i=1}^D \lambda_i (\|f_i(\cdot)\|^2 - 1)$$

根据表示定理，基矢量可以表示为：

$$\mathbf{V}_i = f_i(\cdot) = \sum_{k=1}^n \alpha_{ik} \kappa(\mathbf{x}_k, \cdot) = \sum_{k=1}^n \alpha_{ik} \phi(\mathbf{x}_k)$$

核化PCA方法

● 再生核空间中的优化

基矢量 $\{\mathbf{V}_i\}$ 的表示代入Lagrange函数:

$$\begin{aligned}
 L(\{\boldsymbol{\alpha}_i\}) &= \frac{1}{n} \sum_{k=1}^n \sum_{i=d'+1}^D \left\langle \kappa(\mathbf{x}_k, \cdot), \sum_{l=1}^n \alpha_{il} \kappa(\mathbf{x}_l, \cdot) \right\rangle^2 \\
 &\quad - \sum_{i=1}^D \lambda_i \left(\left\langle \sum_{k=1}^n \alpha_{ik} \kappa(\mathbf{x}_k, \cdot), \sum_{l=1}^n \alpha_{il} \kappa(\mathbf{x}_l, \cdot) \right\rangle - 1 \right) \\
 &= \frac{1}{n} \sum_{i=d'+1}^D \boldsymbol{\alpha}_i^t \mathbf{K}^t \mathbf{K} \boldsymbol{\alpha}_i - \sum_{i=1}^D \lambda_i \boldsymbol{\alpha}_i^t \mathbf{K} \boldsymbol{\alpha}_i
 \end{aligned}$$

其中, $\mathbf{K} = (\kappa(\mathbf{x}_k, \mathbf{x}_l))$ 称为核矩阵, $\boldsymbol{\alpha}_i = (\alpha_{i1}, \dots, \alpha_{in})^t$ 为基矢量 \mathbf{V}_i 的组合系数矢量

核化PCA方法

● KPCA的优化解

计算梯度：

$$\frac{\partial L}{\partial \alpha_i} = \frac{2}{n} \mathbf{K}^t \mathbf{K} \alpha_i - 2\lambda_i \mathbf{K} \alpha_i = 0$$

得到：

$$\mathbf{K} \alpha_i = n \lambda_i \alpha_i$$

$\{\alpha'_1, \dots, \alpha'_{d'}\}$ 为核矩阵 \mathbf{K} 的最大 d' 个特征值 $\{\lambda'_1, \dots, \lambda'_{d'}\}$ 对应的特征矢量，相应的（长度未归一化）基矢量为：

$$\mathbf{V}'_i = \sum_{k=1}^n \alpha'_{ik} \kappa(\mathbf{x}_k, \cdot)$$

核化PCA方法

● 归一化基矢量长度

矢量 \mathbf{V}'_i 的长度平方:

$$\|\mathbf{V}'_i\|^2 = \sum_{k,l=1}^n \alpha'_{ik} \alpha'_{il} \kappa(\mathbf{x}_k, \mathbf{x}_l) = \boldsymbol{\alpha}'_i{}^t \mathbf{K} \boldsymbol{\alpha}'_i = \lambda'_i \|\boldsymbol{\alpha}'_i\|^2$$

令:

$$\boldsymbol{\alpha}_i = \frac{\boldsymbol{\alpha}'_i}{\sqrt{\lambda'_i \|\boldsymbol{\alpha}'_i\|}}$$

则对应的基矢量 \mathbf{V}_i 为单位矢量:

$$\mathbf{V}_i = \sum_{k=1}^n \alpha_{ik} \kappa(\mathbf{x}_k, \cdot)$$

核化PCA方法

- 再生核空间中的投影

矢量 $\phi(\mathbf{x}) = \kappa(\mathbf{x}, \cdot)$ 在基矢量 \mathbf{V}_i 上的投影:

$$\langle \phi(\mathbf{x}), \mathbf{V}_i \rangle = \left\langle \kappa(\mathbf{x}, \cdot), \sum_{k=1}^n \alpha_{ik} \kappa(\mathbf{x}_k, \cdot) \right\rangle = \sum_{k=1}^n \alpha_{ik} \kappa(\mathbf{x}_k, \mathbf{x})$$

核化PCA方法

● 再生核空间中的样本中心化

输入空间的样本均值 $\boldsymbol{\mu} = \mathbf{0}$ ，并不能使得特征空间的样本均值 $\boldsymbol{\mu}_\kappa$ 为 $\mathbf{0}$:

$$\boldsymbol{\mu}_\kappa = \frac{1}{n} \sum_{k=1}^n \phi(\mathbf{x}_k)$$

样本中心化核矩阵 \mathbf{K}' :

$$\begin{aligned} \mathbf{K}'_{ij} &= \langle \phi(\mathbf{x}_i) - \boldsymbol{\mu}_\kappa, \phi(\mathbf{x}_j) - \boldsymbol{\mu}_\kappa \rangle \\ &= \left\langle \kappa(\mathbf{x}_i, \cdot) - \frac{1}{n} \sum_{k=1}^n \kappa(\mathbf{x}_k, \cdot), \kappa(\mathbf{x}_j, \cdot) - \frac{1}{n} \sum_{k=1}^n \kappa(\mathbf{x}_k, \cdot) \right\rangle \\ &= \kappa(\mathbf{x}_i, \mathbf{x}_j) - \frac{1}{n} \sum_{k=1}^n \kappa(\mathbf{x}_i, \mathbf{x}_k) - \frac{1}{n} \sum_{k=1}^n \kappa(\mathbf{x}_k, \mathbf{x}_j) + \frac{1}{n^2} \sum_{k=1}^n \sum_{l=1}^n \kappa(\mathbf{x}_k, \mathbf{x}_l) \end{aligned}$$

写成矩阵形式: ($\mathbf{1}$ 为元素均为1的 $n \times n$ 方阵)

$$\mathbf{K}' = \mathbf{K} - \frac{1}{n} \mathbf{1} \cdot \mathbf{K} - \frac{1}{n} \mathbf{K} \cdot \mathbf{1} + \frac{1}{n^2} \mathbf{1} \cdot \mathbf{K} \cdot \mathbf{1}$$

核化PCA方法

Algorithm 1 KPCA: Kernel Principal Component Analysis

- 1: 输入样本集合 $\{\mathbf{x}_1, \dots, \mathbf{x}_n\}$
- 2: 计算核矩阵 $\mathbf{K} = (\kappa(\mathbf{x}_i, \mathbf{x}_j))$
- 3: 计算中心化核矩阵:

$$\mathbf{K}' = \mathbf{K} - \frac{1}{n} \mathbf{1} \cdot \mathbf{K} - \frac{1}{n} \mathbf{K} \cdot \mathbf{1} + \frac{1}{n^2} \mathbf{1} \cdot \mathbf{K} \cdot \mathbf{1}$$

- 4: 计算 \mathbf{K}' 最大 d' 个特征值 $\lambda'_1, \dots, \lambda'_{d'}$, 特征矢量 $\alpha'_1, \dots, \alpha'_{d'}$
- 5: 基矢量长度归一化:

$$\alpha_i = \frac{\alpha'_i}{\sqrt{\lambda'_i} \|\alpha'_i\|}, \quad i = 1, \dots, d'$$

- 6: 样本 \mathbf{x} 的KPCA投影 \mathbf{y} :

$$y_i = \sum_{k=1}^n \alpha_{ik} \kappa(\mathbf{x}_k, \mathbf{x}), \quad i = 1, \dots, d'$$