



组合优化与凸优化

第4章 一维搜索 (One-dimensional Search)

刘绍辉

计算机科学与技术学院 哈尔滨工业大学

shliu@hit.edu.cn

2022年春季



第4章 一维搜索(One-dimensional Search)



◆精确求解

➤ 缩小区间(Narrowing interval)的精确一维搜索

◆近似求解




几个常见的测试函数

◆ Ackley函数

➤
$$f(x) = -ae \left(-b \sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2} \right) - e^{\frac{1}{d} \sum_{i=1}^d \cos(cx_i)} + a + e$$

➤ 全局极小值在原点


➤ 如 $a = 20, b = 0.2, c = 2\pi$



几个常见的测试函数

◆Booth函数

- $f(x) = (x_1 + 2x_2 - 7)^2 + (2x_1 + x_2 - 5)^2$
- 极小点在(1,3),最优值为0



几个常见的测试函数


◆ Branin函数

➤ $f(x) = a(x_2 - bx_1^2 + cx_1 - r)^2 + s(1 - t)\cos(x_1) + s$

➤ 推荐参数: $a = 1, b = \frac{5.1}{4\pi^2}, c = 5\pi, r = 6, s = 10, t = \frac{1}{8\pi}$

四个全局极小点
 $(-\pi, 12.275), (\pi, 2.275),$
 $(3\pi, 2.475), (5\pi, 12.875)$


若 $x_1 = \pi + 2\pi m, m \in N$, 则无全局极小点



几个常见的测试函数

◆ Flower函数


- $f(x) = a||x|| + b\sin(c \cdot \tan^{-1}(x_2, x_1))$
- 典型参数: $a = 1, b = 1, c = 4$
- 其最小值靠近原点, 但不是原点, 反正切无定义



几个常见的测试函数

◆ Michalewicz函数

- $f(x) = -\sum_{i=1}^d \sin(x_i) \sin^{2m}\left(\frac{ix_i^2}{\pi}\right)$
- 参数 m 典型的选择是10，控制陡峭度
- 全局最小值与维数相关
- 二维约在(2.20,1.57), $f(x^*) = -1.8011$





几个常见的测试函数



◆ Rosenbrock Banana函数

- $f(x) = (a - x_1)^2 - b(x_2 - x_1^2)^2$
- 全局极小点 (a, a^2) , $f(x^*) = 0$
- $a = 1, b = 5$, 极小点为 $(1, 1)$





几个常见的测试函数

◆ Wheeler函数

➤ $f(x) = -e^{-(x_1x_2-a)^2-(x_2-a)^2}$

➤ a 设为 1.5, 在 $(1, -2/3)$ 处取得极小值 -1



几个常见的测试函数

◆ Circle函数

➤ $f(x) = \begin{bmatrix} 1 - r \cos(\theta) \\ 1 - r \sin(\theta) \end{bmatrix}$

➤ $\theta = x_1, r = \frac{1}{2} + \frac{1}{2} \left(\frac{2x_2}{1+x_2^2} \right)$, Pareto前沿 $r = 1, \text{mod}(\theta, 2\pi) \in [0, \frac{\pi}{2}]$ 或者 $r = -1, \text{mod}(\theta, 2\pi) \in [\pi, \frac{3}{2}\pi]$

➤ 多目标测试函数





第4章 一维搜索(One-dimensional Search)

◆一元函数求极小及线性搜索均为一维搜索。常用于求：

$$\begin{cases} \min f(x^{(k)} + \lambda d^{(k)}) = \varphi(\lambda) \\ \text{s.t. } \lambda \in S \end{cases}$$

S 有3种情况 $(-\infty, +\infty)$ 或 $(0, +\infty)$ 或 $[a, b]$

◆缩小区间的精确一维搜索：考虑问题(P)

$$\begin{cases} \min \varphi(\lambda) \\ \text{s.t. } \lambda \in [\alpha, \beta] \end{cases}$$

这里 $\varphi(\lambda): R \rightarrow R$

1、不确定区间及单峰函数

不确定区间: $[\alpha, \beta]$ 含 $\varphi(\lambda)$ 的最小点，但不知其位置

第4章 一维搜索(One-dimensional Search)



◆ 缩小区间的精确一维搜索 (续)


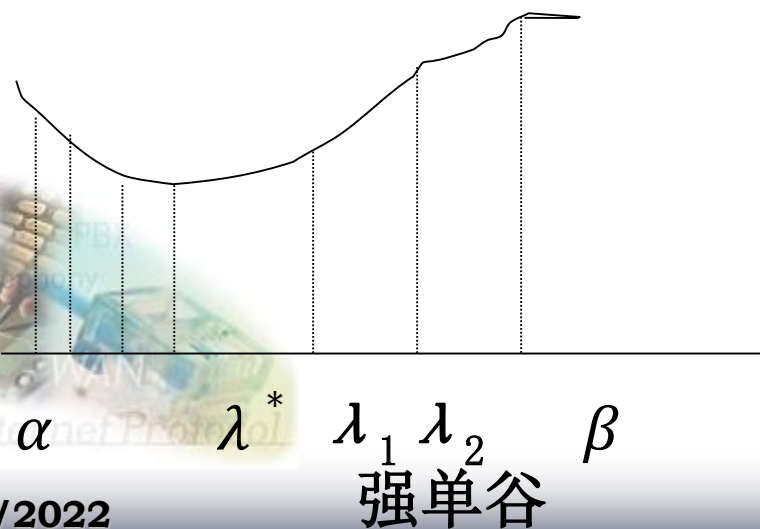
若对任意 $\lambda_1, \lambda_2, \alpha \leq \lambda_1 < \lambda_2 \leq \beta$ 满足:

1° 若 $\lambda_2 \leq \lambda^*$, 则 $\varphi(\lambda_1) > \varphi(\lambda_2)$;

2° 若 $\lambda_1 \geq \lambda^*$, 则 $\varphi(\lambda_1) < \varphi(\lambda_2)$.

则称 $\varphi(\lambda)$ 在 $[\alpha, \beta]$ 上强单谷。

若只有当 $\varphi(\lambda_1) \neq \varphi(\lambda^*)$, $\varphi(\lambda_2) \neq \varphi(\lambda^*)$ 时, 上述1°, 2° 式才成立, 则称 $\varphi(\lambda)$ 在 $[\alpha, \beta]$ 上单谷。



第4章 一维搜索(One-dimensional Search)





◆ 缩小区间的精确一维搜索 (续)

定理： 设 $\Phi: R \rightarrow R$ 在 $[\alpha, \beta]$ 上单谷， $\alpha \leq \lambda < \mu \leq \beta$ ，则有：

1° 若 $\Phi(\lambda) \geq \Phi(\mu)$ ，则 $\Phi(\rho) \geq \Phi(\mu), \forall \rho \in [\alpha, \lambda]$ ；如左下图

2° 若 $\Phi(\lambda) < \Phi(\mu)$ ，则 $\Phi(\rho) \geq \Phi(\lambda), \forall \rho \in [\mu, \beta]$ ；如右下图



第4章 一维搜索(One-dimensional Search)



◆ 缩小区间的精确一维搜索（续）

证明：1° 反证：设 $\lambda^* \in [\alpha, \beta]$ 为最小点, $\gamma \in [\alpha, \lambda]$ 及 $\gamma < \lambda < \lambda^*$, 使 $\Phi(\gamma) < \Phi(\mu) < \Phi(\lambda)$,


➤ 若 $\lambda^* \in [\lambda, \beta]$, 由定义 $\Phi(\gamma) > \Phi(\lambda)$, 矛盾（假设）；

➤ 若 $\lambda^* \in [\alpha, \lambda)$, 由定义及 $\mu > \lambda \geq \lambda^*$, $\Phi(\mu) > \Phi(\lambda)$ 矛盾（条件）；

于是结论成立。

2° 的证明类似（略）。

注：上述定理为缩短区间的算法提供了理论根据



第4章 一维搜索(One-dimensional Search)



◆ 缩小区间的精确一维搜索 (续)

2、黄金分割法 (0.618 法)

通过上述定理, 选二点 $\lambda < \mu$, 比较 $\Phi(\lambda)$ 与 $\Phi(\mu)$, 可去掉 $[\alpha, \lambda]$ 或者 $[\mu, \beta]$. 考虑条件:


1° 对称: $\lambda - \alpha = \beta - \mu$ (1)

使“坏”的情况去掉, 区间长度不小于“好”的情况

2° 保持缩减比: $t = (\text{保留的区间长度} / \text{原区间长度})$ 不变。

使每次保留下来的节点 λ 或 μ , 在下一次的比较中成为一个相应比例位置的节点

推导缩减比 t : 如图设第一次保留 $[\alpha, \mu]$ (去掉 $[\mu, \beta]$), 那么第二次保留的长度为 $[\alpha, \lambda]$, 则



$$t = \frac{\mu - \alpha}{\beta - \alpha} = \frac{\lambda - \alpha}{\mu - \alpha} \dots\dots(2)$$

第4章 一维搜索(One-dimensional Search)



◆ 缩小区间的精确一维搜索

2、黄金分割法 (0.618 法) (续)

整理②：

$$\begin{cases} \mu = \alpha + t(\beta - \alpha) \\ \lambda = \alpha + t(\mu - \alpha) \end{cases}$$

结合①式： $t^2 + t - 1 = 0$

故 $t \approx 0.618$

$$t = \frac{-1 \pm \sqrt{5}}{2} \text{ (舍去负值)}$$

注意 上式有 $t^2 = 1 - t$, 故有

$$\begin{cases} \mu = \alpha + t(\beta - \alpha) \\ \lambda = \alpha + (1 - t)(\beta - \alpha) \end{cases}$$

算法框图如下

第4章 一维搜索(One-dimensional Search)



◆ 缩小区间的精确一维搜索 之 黄金分割法 (0.618 法)

初始 $[\alpha, \beta], \varepsilon > 0$
 $t = (\sqrt{5} - 1) / 2$

$$\lambda = \alpha + (1 - t)(\beta - \alpha)$$
$$\mu = \alpha + t(\beta - \alpha)$$

$\beta - \alpha < \varepsilon?$

yes

STOP;
 $\lambda^* = (\alpha + \beta) / 2$

No


$\Phi(\lambda) - \Phi(\mu) > 0?$

No

$$\beta = \mu, \mu = \lambda$$
$$\lambda = \alpha + (1 - t)(\beta - \alpha)$$

yes

$$\alpha = \lambda, \lambda = \mu$$
$$\mu = \alpha + t(\beta - \alpha)$$



第4章 一维搜索(One-dimensional Search)



◆ 与黄金分割法类似的方法还有Fibonacci法，区别在于搜索区间长度的缩短率不是黄金分割数，而是Fibonacci数，

- $F_1 = F_2 = 1, F_n = F_{n-1} + F_{n-2}, n \geq 3$
- 假设最后满足要求的区间为 I_n ,则倒数第二个区间宽度为 $F_2 I_n$,倒数第3个区间宽度为 $F_3 I_n \dots$


$$I_1 = I_2 + I_3 = 8I_5$$


$$I_2 = I_3 + I_4 = 5I_5$$


$$I_3 = I_4 + I_5 = 3I_5$$


$$I_4 = 2I_5$$


$$I_5$$


◆ 缩短率 $b_{k+1} - a_{k+1} = \frac{F_{n-k}}{F_{n-k+1}}(b_k - a_k)$,要求 n 次后, $b_n - a_n \leq \delta$,实际上, 当 $n \rightarrow \infty$,
 $\lim_{n \rightarrow \infty} \frac{F_n}{F_{n+1}} = (\sqrt{5}-1)/2$; $b_n - a_n = \frac{1}{F_n}(b_1 - a_1)$,选择合适的 n ,使得精度符合要求。

第4章 一维搜索(One-dimensional Search)

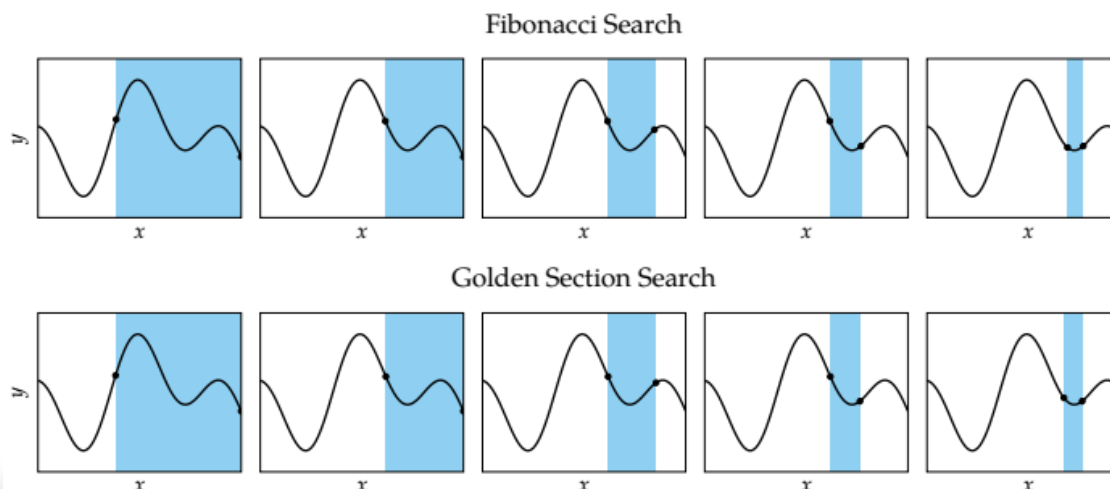


◆比较Fibonacci和黄金分割搜索方法

➤单模函数



➤非单模函数



第4章 一维搜索(One-dimensional Search)



◆3、中点法(二分法)



设 $\phi(\lambda)$ 在 $[\alpha, \beta]$ 上可微, 且当导数为零时是解。取 $\lambda = (\alpha + \beta) / 2$, 那么

$\phi'(\lambda) = 0$ 时, λ 为最小点, $\lambda = \lambda^*$;

$\phi'(\lambda) > 0$ 时, λ 在上升段, $\lambda^* < \lambda$, 去掉 $[\lambda, \beta]$;

$\phi'(\lambda) < 0$ 时, λ 在下降段, $\lambda^* > \lambda$, 去掉 $[\alpha, \lambda]$;

(算法框图略)



第4章 一维搜索(One-dimensional Search)



4、进退法求初始不确定区间

找三点使两端点的函数值大于中间点的函数值。

思路：任取 λ_0 ，步长 $\delta > 0$ ，取 $\lambda_1 = \lambda_0 + \delta$ ，

1° 若 $\Phi(\lambda_0) < \Phi(\lambda_1)$ ，令 $\delta = 2\delta$ （步长加倍）， $\lambda_2 = \lambda_0 - \delta$ ，

$\left\{ \begin{array}{l} \text{若 } \Phi(\lambda_2) < \Phi(\lambda_0), \text{ 则令 } \lambda_1 = \lambda_0, \lambda_0 = \lambda_2, \text{ 重复 } 1^\circ \\ \text{若 } \Phi(\lambda_2) > \Phi(\lambda_0), \text{ 则停, } \alpha = \lambda_2, \beta = \lambda_1 \text{ (图1)} \end{array} \right.$

2° 若 $\Phi(\lambda_0) > \Phi(\lambda_1)$ ，令 $\delta = 2\delta$ ， $\lambda_2 = \lambda_1 + \delta$ ，

$\left\{ \begin{array}{l} \text{若 } \Phi(\lambda_2) < \Phi(\lambda_1), \text{ 则令 } \lambda_0 = \lambda_1, \lambda_1 = \lambda_2, \text{ 重复 } 2^\circ \\ \text{若 } \Phi(\lambda_2) > \Phi(\lambda_1), \text{ 则停, } \alpha = \lambda_0, \beta = \lambda_2 \text{ (图2)} \end{array} \right.$





图1




图2

第4章 一维搜索(One-dimensional Search)



4、进退法求初始不确定区间（续）

（自己画算法框图）

◆注意

- δ 选择要适当。（太大含多个单峰区间，太小迭代次数增加）；
- $\Phi(\lambda)$ 单调时无结果，(加迭代次数限制)；
- 可与中点法结合寻找单调区间（思考）





◆ 牛顿法 (Newton) 和插值法

- 插值法利用插值函数逼近所需求解的目标函数，把插值函数的极小点作为迭代点。常见的有三点二次插值，两点二次插值和三次插值多项式

1、Newton法:

对 Φ 在 λ_k 点展开:

$$\Phi(\lambda) = \Phi(\lambda_k) + \Phi'(\lambda_k)(\lambda - \lambda_k) + (1/2)\Phi''(\lambda_k)(\lambda - \lambda_k)^2 + O(\lambda - \lambda_k)^2$$

取二次式(略去高阶项):

$$q_k(\lambda) = \Phi(\lambda_k) + \Phi'(\lambda_k)(\lambda - \lambda_k) + \frac{1}{2}\Phi''(\lambda_k)(\lambda - \lambda_k)^2$$



第4章 一维搜索-Newton和插值法

◆牛顿法（Newton）和插值法

1、Newton法：（续）

用 $q_k(\lambda)$ 作为 $\Phi(\lambda)$ 的近似，当 $\Phi''(\lambda_k) > 0$ 时，其驻点为极小点：

$$q'_k(\lambda) = \Phi'(\lambda_k) + \Phi''(\lambda_k)(\lambda - \lambda_k) = 0$$

得 $\lambda_{k+1} = \lambda_k - \Phi'(\lambda_k)/\Phi''(\lambda_k)$

取 λ_{k+1} 为新的迭代点。以上过程即Newton法。

特点：二阶、局部收敛。

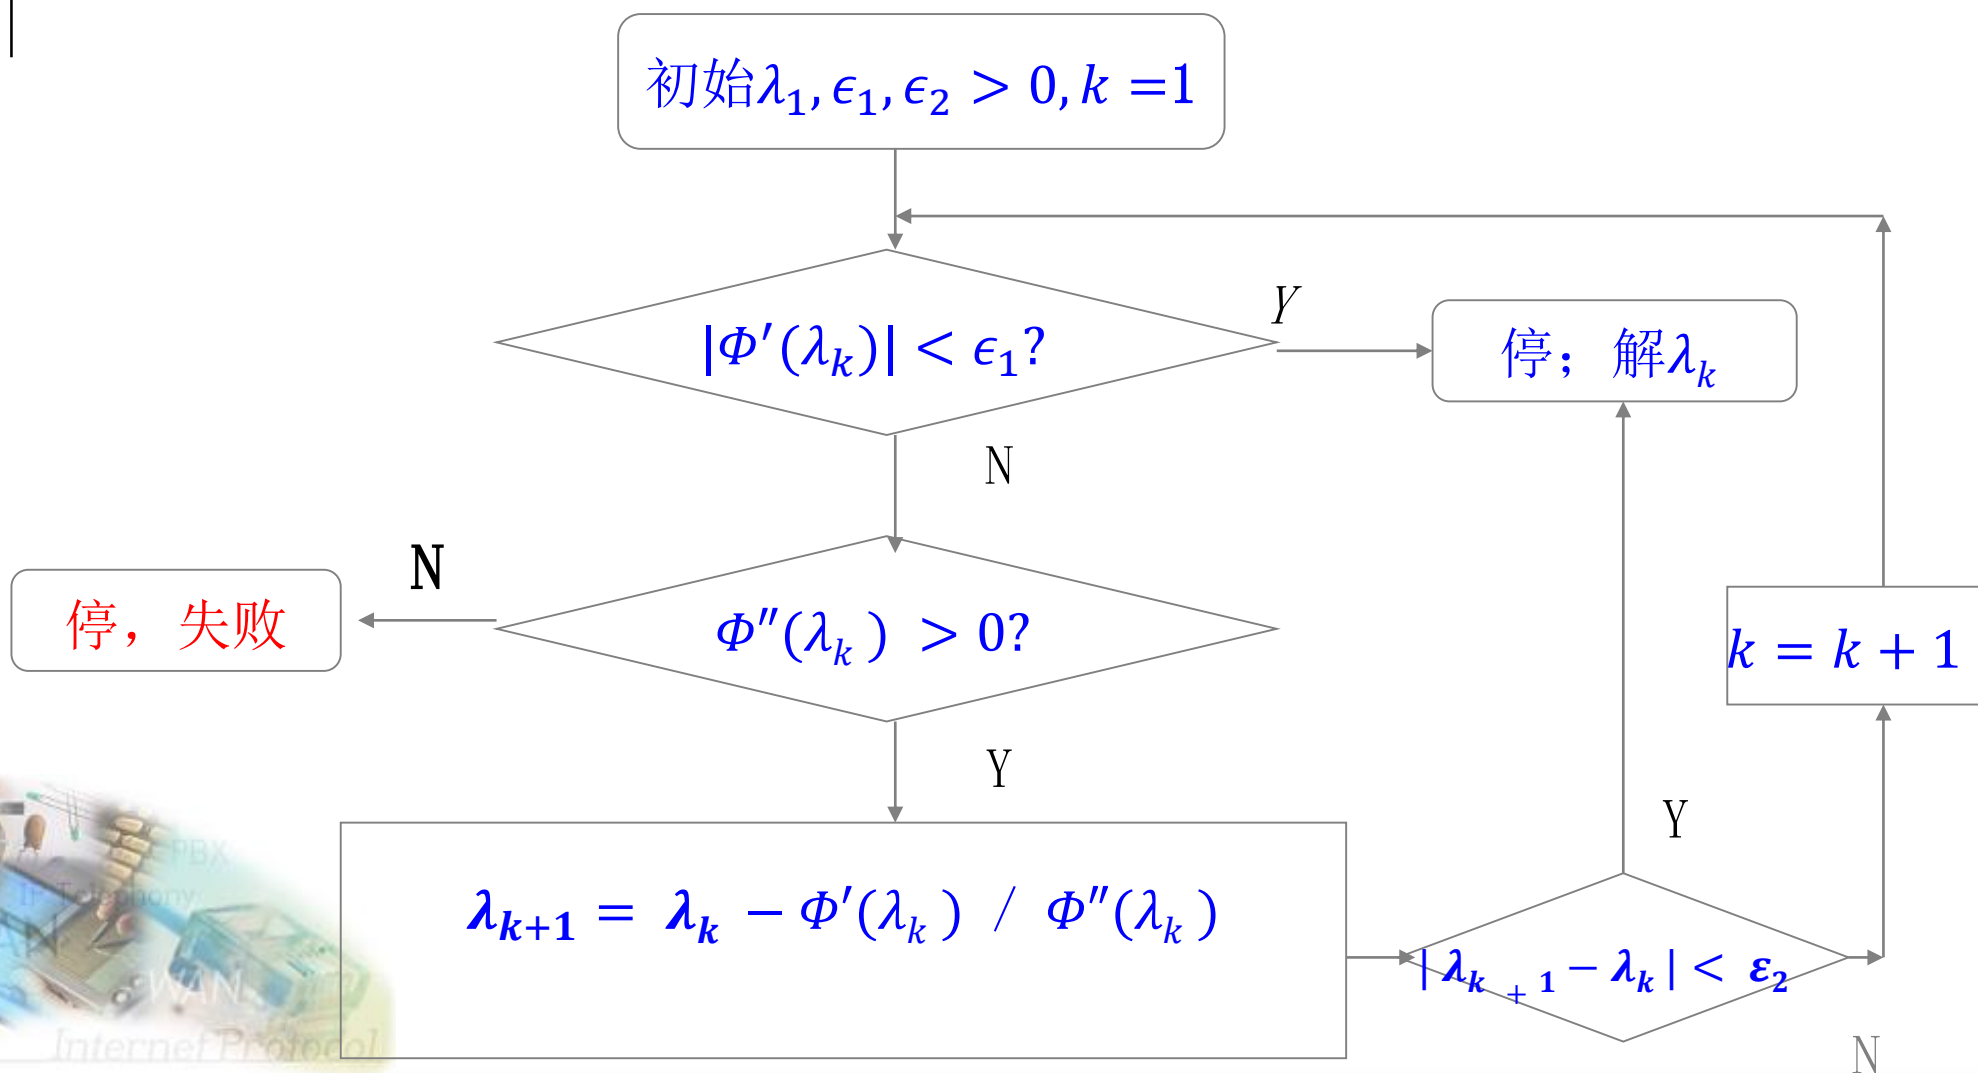
算法框图如下



第4章 一维搜索-Newton和插值法



◆Newton法算法框图:





第4章 一维搜索-Newton和插值法

二、牛顿法 (Newton) 和插值法

1、Newton法： (续)

例. 求 $\min \Phi(\lambda) = \int_0^{\lambda} \arctan t dt$

解: $\Phi'(\lambda) = \arctan \lambda$, $\Phi''(\lambda) = 1 / (1 + \lambda^2)$

迭代公式: $\lambda_{k+1} = \lambda_k - (1 + \lambda_k^2) \arctan \lambda_k$

取 $\lambda_1 = 1$, 计算结果:

k	λ_k	$\Phi'(\lambda_k)$	$1 / \Phi''(\lambda_k)$
1	1	0.7854	2
2	-0.5708	-0.5187	1.3258
3	0.1169	-0.1164	1.0137
4	-0.001095	-0.001095	

$$\lambda_4 \approx \lambda^* = 0$$

取 $\lambda_1 = 2$, 计算结果如下:



第4章 一维搜索-Newton和插值法

二、牛顿法 (Newton) 和插值法

1、Newton法： (续)

k	λ_k	$\Phi'(\lambda_k)$	$1 / \Phi''(\lambda_k)$
1	2	1.1071	5
2	-3.5357	-1.2952	13.50
3	13.95	不收敛。	

- ◆ 牛顿法的基本思想是在迭代点 $x^{(k)}$ 附近用二次函数 $q^{(k)}(s) = f(x^{(k)}) + g_k^T s + \frac{1}{2} s^T G_k s$ 来逼近 $f(x)$,并以 $q^{(k)}(s)$ 的极小点 $s^{(k)}$ 来修正 $x^{(k)}$,得到 $x^{(k+1)} = x^{(k)} + s^{(k)}$





第4章 一维搜索-Newton和插值法

二、牛顿法 (Newton) 和插值法

1、Newton法： (续)

k	λ_k	$\Phi'(\lambda_k)$	$1 / \Phi''(\lambda_k)$
1	2	1.1071	5
2	-3.5357	-1.2952	13.50
3	13.95	不收敛	

2、插值法：

用 $\phi(\lambda)$ 在 2 或 3 个点的函数值或导数值，构造 2 次或 3 次多项式作为 $\phi(\lambda)$ 的近似值，以这多项式的极小点为新的迭代点

3点2次，2点2次，4点3次，3点3次，2点3次等

以3点2次为例：

取 $\lambda_1, \lambda_2, \lambda_3$ ，求出 $\phi(\lambda_1), \phi(\lambda_2), \phi(\lambda_3)$



第4章 一维搜索-Newton和插值法

◆ 牛顿法 (Newton) 和插值法

2、插值法：（续）


设二次插值多项式： $a\lambda^2 + b\lambda + c = \phi(\lambda)$

$$\begin{cases} a\lambda_1^2 + b\lambda_1 + c = \phi(\lambda_1) \\ a\lambda_2^2 + b\lambda_2 + c = \phi(\lambda_2) \\ a\lambda_3^2 + b\lambda_3 + c = \phi(\lambda_3) \end{cases} \quad \text{解得 } a, b$$

$$a = - \frac{(\lambda_1 - \lambda_2)\Phi(\lambda_3) + (\lambda_2 - \lambda_3)\Phi(\lambda_1) + (\lambda_3 - \lambda_1)\Phi(\lambda_2)}{(\lambda_1 - \lambda_2)(\lambda_2 - \lambda_3)(\lambda_3 - \lambda_1)}$$

$$b = \frac{(\lambda_1^2 - \lambda_2^2)\Phi(\lambda_3) + (\lambda_2^2 - \lambda_3^2)\Phi(\lambda_1) + (\lambda_3^2 - \lambda_1^2)\Phi(\lambda_2)}{(\lambda_1 - \lambda_2)(\lambda_2 - \lambda_3)(\lambda_3 - \lambda_1)}$$

$$\bar{\lambda} = - \frac{b}{2a}$$



第4章 一维搜索-Newton和插值法




◆ 2、插值法：（续）

- 上述及得4个已知点，设为 $\lambda_0, \bar{\lambda}, \lambda_1, \lambda_2$ ，然后从中舍去一个，保证最小点在区间内
- 怎么保证？初始三点如何选取？

◆ 两点两次

- 两点 λ_0, λ_1 函数值及一点的导数值， $\psi(\lambda) = a\lambda^2 + b\lambda + c$ ，从而可得



复这个过程

- 特点：简单，不必预先确定上下界，但函数单调时得不到结果

第4章 一维搜索-Newton和插值法



◆三次插值：四个参数

➤ 因此需要四个条件：可以是四个点，3点加一点的导数值，2点加两点导数值

◆ 实用中，特别对单变量问题求最小点时，利用上面的方法相互配合，会收到较好的结果

◆ 总体来说，精确一维搜索需要花费很大的工作量，特别是当迭代点远离问题的解的时候，精确求解一个一维子问题通常不是十分有效

◆ 实际上，牛顿法和拟牛顿法的收敛速度并不依赖于精确一维搜索，因此只要保证目标函数值每一步都有满意的下降，这样可以大大节省工作量


◆ 上述方法一般都收敛到局部极小点，而无法收敛到全局极小点

第4章 一维搜索-Shubert-Piyavskii方法



- ◆ 能收敛到全局极小点
- ◆ 如果函数是Lipschitz连续：即导数的幅度存在上界
 - $|f(x) - f(y)| \leq l|x - y|, \forall x, y \in [a, b]$, 可推广到向量和范数
 - 给定点 $(x_0, f(x_0))$, 若 $x > x_0$, 直线 $f(x_0) - l(x - x_0)$; $x < x_0, f(x_0) + l(x - x_0)$ 形成函数 f 的下界
- ◆ 给定李普希兹常数 l , 算法从中点 $x^{(1)} = \frac{a+b}{2}$, 通过该点斜率为 $\pm l$ 的直线构造 f 的锯齿样下界。如果常数 l 有效, 这些直线总是在函数 f 的下面

一步步构建
函数的下界




第4章 一维搜索-Shubert-Piyavskii方法



◆Shubert-Piyavskii

- 算法在最小的锯齿点 $(x^{(n)}, y^{(n)})$ 与该点的函数值 $f(x^{(n)})$ 之差小于某个小常数的时候停止
- $y^{(n)} - f(x^{(n)}) < \epsilon$

不断迭代找到锯齿线的最小值点，并计算改点的函数值来更新锯齿



- 每次迭代中，最小值所在的不确定区域计算为：

- $\left[x^{(i)} - \frac{1}{l} (f(x_{min}) - y^{(i)}), x^{(i)} + \frac{1}{l} (y^{(i)} - y_{min}) \right]$

这里 $(x^{(i)}, y^{(i)})$ 为下锯齿顶点， (x_{min}, y_{min}) 为最小的上锯齿顶点

- 只有当 $y^{(i)} < y_{min}$ 时，这个点对确定区域有贡献

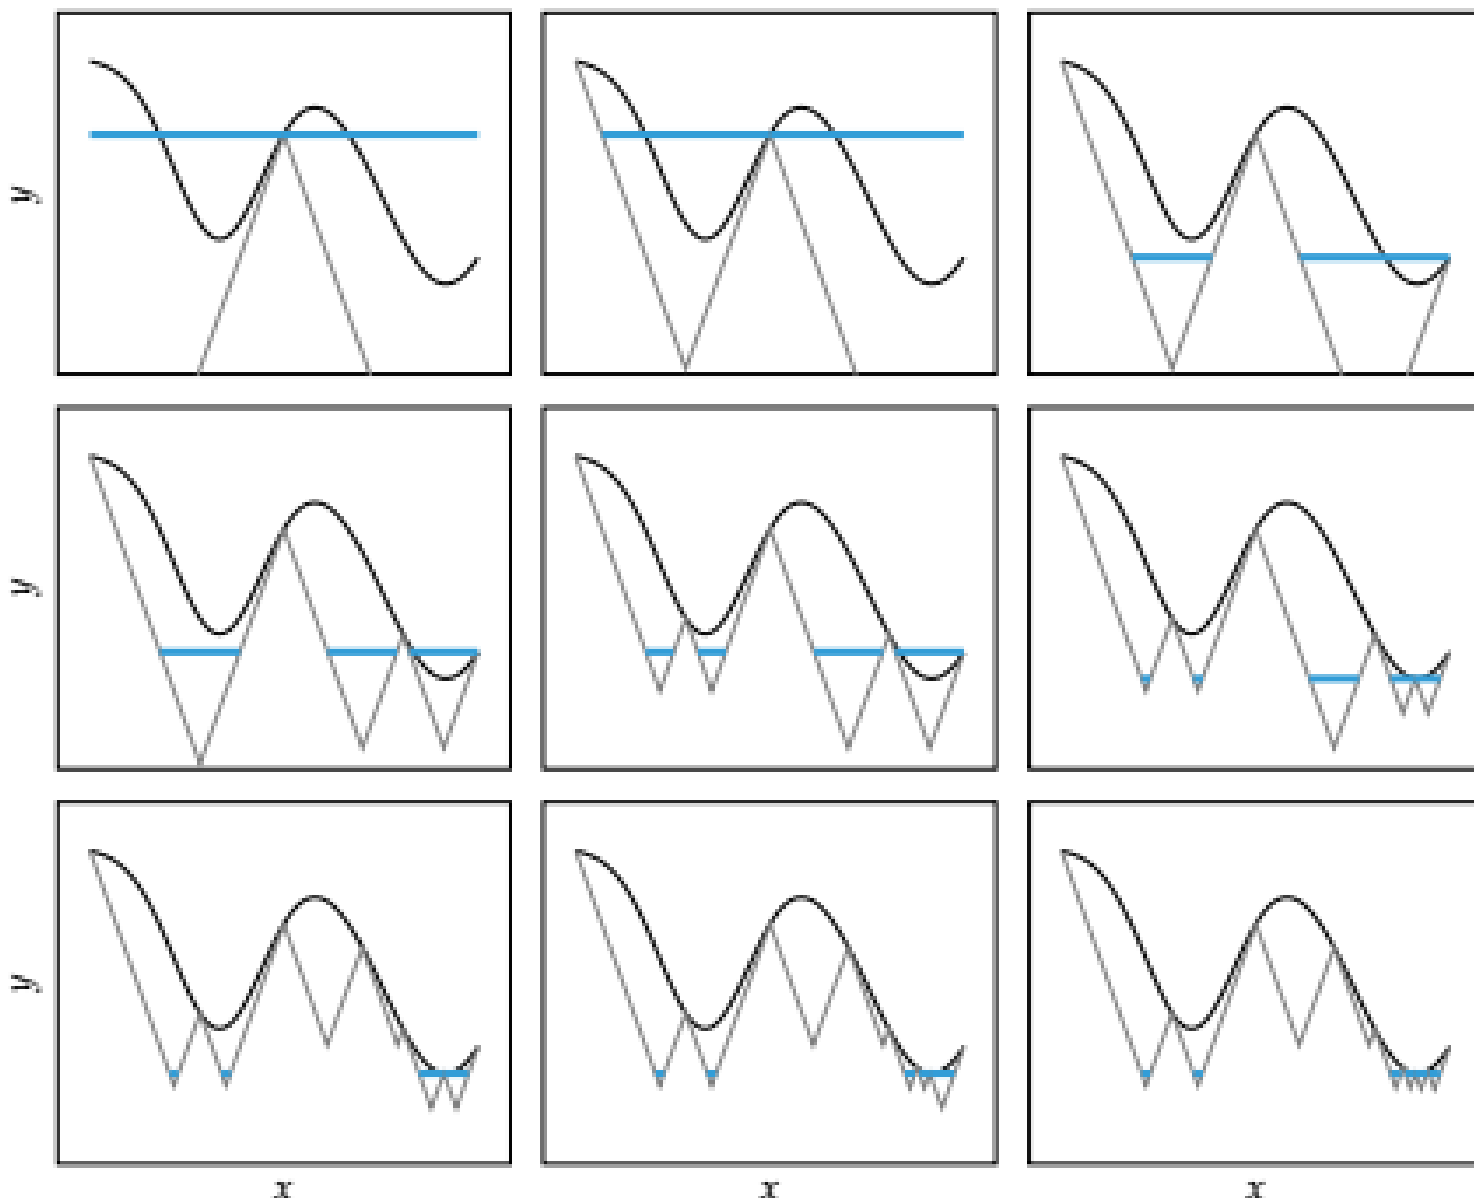
第4章 一维搜索-Shubert-Piyavskii方法



◆例子

◆缺点？

要求李普希兹常数 L ，
越大下界越差





第4章 一维搜索-不精确搜索

◆ 下降方向法 $x^{(k+1)} = x^{(k)} + \lambda d^{(k)}$, 确定方向后, 需要计算步长

- 大步长收敛快, 但可能错过最优值
- 小步长收敛慢
- 固定步长有时称为学习率
- 或者使用 $\lambda_k = \lambda_1 \gamma^{k-1}$, $\gamma \in (0, 1)$ 这样的衰减步长因子
- 是否还有别的方法?





第4章 一维搜索-不精确搜索

◆不精确一维搜索： $\min f(x)$

考虑从 $x^{(k)}$ 点出发，沿方向 $d^{(k)}$ 寻找新迭代点： $x^{(k)} + \lambda_k d^{(k)}$

要求：1° $f(x^{(k)} + \lambda_k d^{(k)}) < f(x^{(k)})$;

2° $\lambda_k > 0$ 不能太小。

总体希望收敛快，每一步不要求达到精确最小，速度快，随着步数增加，则整个过程达到收敛。

◆Goldstein法：是一个实用方法

➤ 设 $f: R^n \rightarrow R$ 。在 x 取方向 d ，有 $\nabla f^T(x)d < 0$ (即 d 为下降方向)，令 $s^{(k)} = x^{(k+1)} - x^{(k)} = \lambda_k d^{(k)}$ 求 λ 使

$$(1) f(x^{(k+1)}) - f(x^{(k)}) \leq \rho \nabla f^T(x^{(k)}) s^{(k)}$$


$$(2) f(x^{(k+1)}) - f(x^{(k)}) \geq (1 - \rho) \nabla f^T(x^{(k)}) s^{(k)}$$

其中 $\rho \in (0, \frac{1}{2})$ ，实际中常取 $\rho = 0.1$ 或更小

思考这两个条件的意义？

第4章 一维搜索-不精确搜索

◆不精确一维搜索(续)



$$(1) f(x^{(k+1)}) - f(x^{(k)}) \leq \rho \nabla f^T(x^{(k)}) s^{(k)}$$

$$(2) f(x^{(k+1)}) - f(x^{(k)}) \geq (1 - \rho) \nabla f^T(x^{(k)}) s^{(k)}$$

$$y = f(x^{(k)}) + \rho \nabla f^T(x^{(k)}) d^{(k)} \lambda$$

$$f(x^{(k)} + \lambda d^{(k)})$$

可接受范围


可接受范围

λ

$$y = f(x^{(k)}) + (1 - \rho) \nabla f^T(x^{(k)}) d^{(k)} \lambda$$

◆经常在牛顿类方法中使用，但不太适合拟牛顿方法

◆七次线搜索





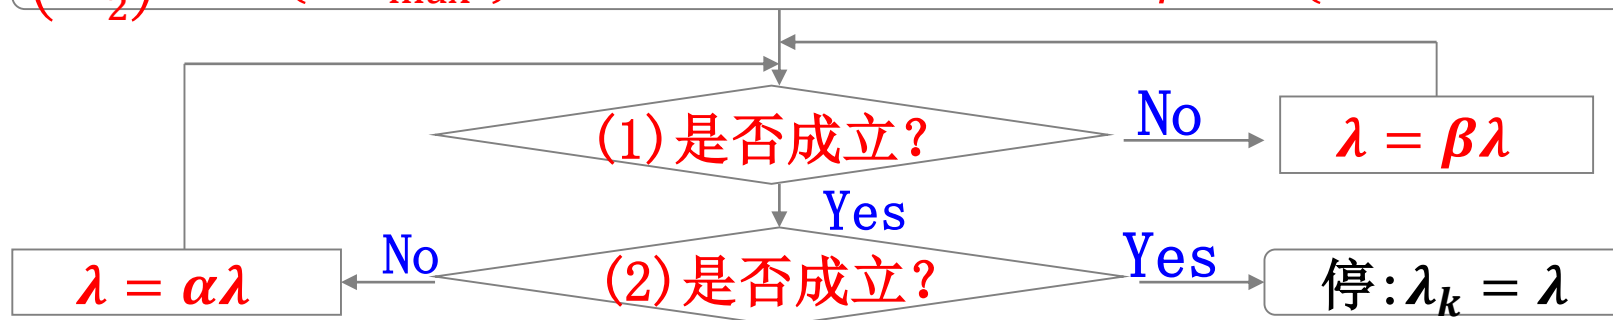
第4章 一维搜索-不精确搜索

$$(1) f(x^{(k+1)}) - f(x^{(k)}) \leq \rho \nabla f^T(x^{(k)}) s^{(k)}$$

$$(2) f(x^{(k+1)}) - f(x^{(k)}) \geq (1 - \rho) \nabla f^T(x^{(k)}) s^{(k)}$$

◆ 不精确一维搜索(续)

$\rho \in \left(0, \frac{1}{2}\right), \lambda \in (0, \lambda_{\max}), \alpha > 1$ (步长增大系数), $\beta < 1$ (步长缩短系数)



◆ 一般 α, β 的选择要适当, 一般选取 $\alpha = 1.5, \beta = 0.5$, 一般情况下迭代几步就可得到解, 利用这种不精确一维搜索, 不少算法可以得到全局收敛性结果

◆ 1966年, Armijo给出与Goldstein法类似的不精确一维搜索规则, 相当于替换(2)中的 $(1 - \rho) \rightarrow \mu\rho, \mu$ 取5-10

◆ 1967年, Goldstein提出更一般的方法, 把(2)式改为:

$$f(x^{(k+1)}) \geq f(x^{(k)}) + \sigma \nabla f^T(x^{(k)}) s^{(k)}, \text{其中 } \sigma \in (\rho, 1)$$



◆ Wolfe-Powell方法(1969,1976)

➤ 前面Goldstein方法中规则(2)改为对导数的要求

✓ (WP规则1) $f(x^{(k+1)}) \leq f(x^{(k)}) + \rho \nabla f^T(x^{(k)})s^{(k)}$

✓ (WP规则2) $\nabla f^T(x^{(k+1)})s^{(k)} \geq \sigma \nabla f^T(x^{(k)})s^{(k)}$

➤ 其中 $\rho \in (0, \frac{1}{2})$, $\sigma \in (\rho, 1)$

◆ WP规则(1)的意义如前


◆ WP规则(2)的意义?

➤ 表示要求在 $x^{(k+1)}$ 点对应的斜率不小于 $\sigma \nabla f^T(x^{(k)})d^{(k)}$



第4章 一维搜索-不精确搜索

◆ 图示





第4章 一维搜索-不精确搜索

◆ Wolfe-Powell方法(1969,1976)

- **(WP规则1)** $f(x^{(k+1)}) \leq f(x^{(k)}) + \rho \nabla f^T(x^{(k)})s^{(k)}$
- **(WP规则2)** $\nabla f^T(x^{(k+1)})s^{(k)} \geq \sigma \nabla f^T(x^{(k)})s^{(k)}$
- 其中 $\rho \in (0, \frac{1}{2})$, $\sigma \in (\rho, 1)$

- ◆ 算法步骤如Goldstein类似，一般以 $\lambda = 1$ 优先
- ◆ 此方法实算时，平均只需要2-3次函数值计算即可求得 λ_k ,对提高整体速度很有效。这个方法用于某些多变量算法中的线性搜索可得全局收敛性结果
- ◆ 如果需要较高的精度时，**WP规则(2)**可进一步改为：

$$\text{(WP改进规则2)} \quad |\nabla f^T(x^{(k+1)})d^{(k)}| \leq -\eta \nabla f^T(x^{(k)})d^{(k)}, \eta \in (0, 1)$$

- ◆ 显然当 $\eta = 0$,此即为精确一维搜索，但该方法不需要预先求出不确定区间，使用较为方便，又便于通过调整 η 来调整精确度要求，因而也常当做近似的精确一维搜索使用。当 $\eta = 0.1$ 时，就可以看做近似的精确一维搜索
- ◆ 在绝大多数线搜索方法中使用，尤其适合拟牛顿方法

◆ 足够下降和回溯 (Backtracking) 方法

➤ 一般来说, 目标函数值的充分下降并不能保证算法沿搜索方向有合理的进展, 但如果线索搜通过采用所谓的 backtracking 方法可以获得合适的候选步长, 也可以达到目标

➤ 算法如下 (backtracking 线搜索) :

选择 $\alpha_0 > 0, \rho \in (0, 1), c \in (0, 1)$; 令 $\alpha \leftarrow \alpha_0$;

Repeat until $f(x^{(k)} + \alpha p_k) \leq f(x^{(k)}) + c\alpha \nabla f_k^T p_k$

$\alpha \leftarrow \rho\alpha$;

End(repeat)

终止令 $\alpha_k = \alpha$.

✓ 初始步长 α_0 在牛顿和拟牛顿方法中设为1, 但在最速下降或共轭梯度中采用别的值, ρ 值在迭代中可以变化, 例如 $0 < \rho_{low} < \rho < \rho_{high} < 1$

✓ 方法比较适合牛顿法, 但不太适合拟牛顿和共轭梯度法



第4章 一维搜索-不精确搜索

◆ Zoutendijk定理

- 优化中的迭代步骤中，方向 p_k 为下降方向， α_k 满足Wolfe条件（别的条件也都可以）。假设 f 在 R^n 上下有界并在包含水平集 $L = \{x: f(x) < f(x^{(0)})\}$ 的开集 N 上连续可微， $x^{(0)}$ 为迭代初始点，并假设 ∇f 在 N 上是Lipschitz连续的，即：

$$\|\nabla f(x) - \nabla f(\tilde{x})\| \leq L\|x - \tilde{x}\|, \forall x, \tilde{x} \in N$$

- 则有： $\sum_{k \geq 0} \cos^2 \theta_k \|\nabla f_k\|^2 < \infty$ ---zoutendijk条件

- 注意： $\cos \theta_k = \frac{-\nabla f_k^T p_k}{\|\nabla f_k\| \|p_k\|}$

- Lipschitz连续一般由平滑性假设都可以获得，因此在实际问题中一般都满足。由zoutendijk条件意味着 $\cos^2 \theta_k \|\nabla f_k\|^2 \rightarrow 0$ ，如果角度满足 $\cos \theta_k \geq \delta > 0, \forall k$ ，则立得： $\lim_{k \rightarrow \infty} \|\nabla f_k\| = 0$

- 在拟牛顿方法中， $p_k = -B_k \nabla f_k$ ，若正定矩阵 $\|B_k\| \|B_k^{-1}\| \leq M, \forall k$ ，则有 $\cos \theta_k \geq \frac{1}{M}$ ，利用zoutendijk条件，则有 $\lim_{k \rightarrow \infty} \|\nabla f_k\| = 0$ ，意味着满足Wolfe条件的牛顿和拟牛顿方法，其偏转矩阵正定，具有有界条件数，则其全局收敛

第4章 一维搜索-最速下降法的收敛速率



- ◆ 对对称正定二次函数 $f(x) = \frac{1}{2}x^T Qx - b^T x + c$ 应用最速下降法则
有：

$$x^{(k+1)} = x^{(k)} - \left(\frac{\nabla f_k^T \nabla f_k}{\nabla f_k^T Q \nabla f_k} \right) \nabla f_k$$

- ◆ 令 $\|x\|_Q^2 = x^T Qx$, 则 $\frac{1}{2}\|x - x^*\|_Q^2 = f(x) - f(x^*)$ -----误差范数,

$$\frac{1}{2}\|x - x^*\|_Q^2 = \left\{ 1 - \frac{(\nabla f_k^T \nabla f_k)^2}{(\nabla f_k^T Q \nabla f_k)(\nabla f_k^T Q^{-1} \nabla f_k)} \right\} \|x^{(k)} - x^*\|_Q^2$$

- ◆ 定理：当上述精确线搜索用于强凸二次函数时，其误差范数满足
：

$$\|x^{(k+1)} - x^*\|_Q^2 \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^2 \|x^{(k)} - x^*\|_Q^2$$

- ◆ 这里 $\lambda_n \geq \lambda_{n-1} \geq \dots \geq \lambda_2 \geq \lambda_1 > 0$ 为 Q 的特征值

第4章 一维搜索-最速下降法的收敛速率



- ◆ 假设函数 $f: R^n \rightarrow R$ 是连续二次可微，精确线索搜的最速下降法收敛到点 x^* ，该点的Hessian矩阵 $\nabla^2 f(x^*)$ 正定。令 $r \in \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}, 1\right)$ ，这里 $\lambda_n \geq \lambda_{n-1} \geq \dots \geq \lambda_2 \geq \lambda_1 > 0$ 为 $\nabla^2 f(x^*)$ 的特征值，则对足够大的 k ，有：
- ◆ $f(x^{(k+1)}) - f(x^*) \leq r^2 [f(x^{(k)}) - f(x^*)]$
- ◆ 因此，一般不能期望非精确线索搜能改进收敛速度。即使其二阶Hessian矩阵具有良好的性质，例如条件数，也不能保证其快速收敛！
- ◆ 实际上，如何设计快速的能收敛的算法，一直是优化中的重点和难点！



第4章 一维搜索-结束

◆一维搜索

◆精确一维搜索

➤没有利用导数信息

✓黄金分割方法

✓斐波那契方法

➤利用导数信息

✓Newton法

✓插值法

◆近似一维搜索

➤Goldstein法、Armijo

➤Wolfe-Powell方法

✓一般2-3步找到