



组合优化与凸优化

第4章 一维搜索 (One-dimensional Search)

刘绍辉

计算机科学与技术学院 哈尔滨工业大学

shliu@hit.edu.cn

2023年春季



# 第4章 一维搜索(One-dimensional Search)



## ◆精确求解

➤ 缩小区间(Narrowing interval)的精确一维搜索

## ◆近似求解




# 几个常见的测试函数

## ◆ Ackley函数

➤ 
$$f(x) = -ae \left( -b \sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2} \right) - e^{\frac{1}{d} \sum_{i=1}^d \cos(cx_i)} + a + e$$

➤ 全局极小值在原点


➤ 如  $a = 20, b = 0.2, c = 2\pi$



# 几个常见的测试函数

## ◆Booth函数

- $f(x) = (x_1 + 2x_2 - 7)^2 + (2x_1 + x_2 - 5)^2$
- 极小点在(1,3),最优值为0



# 几个常见的测试函数


## ◆ Branin函数

➤  $f(x) = a(x_2 - bx_1^2 + cx_1 - r)^2 + s(1 - t)\cos(x_1) + s$

➤ 推荐参数:  $a = 1, b = \frac{5.1}{4\pi^2}, c = 5\pi, r = 6, s = 10, t = \frac{1}{8\pi}$

四个全局极小点  
 $(-\pi, 12.275), (\pi, 2.275),$   
 $(3\pi, 2.475), (5\pi, 12.875)$


若  $x_1 = \pi + 2\pi m, m \in N$ , 则无全局极小点



# 几个常见的测试函数

## ◆ Flower函数


- $f(x) = a||x|| + b\sin(c \cdot \tan^{-1}(x_2, x_1))$
- 典型参数:  $a = 1, b = 1, c = 4$
- 其最小值靠近原点, 但不是原点, 反正切无定义



# 几个常见的测试函数

## ◆ Michalewicz函数

- $f(x) = -\sum_{i=1}^d \sin(x_i) \sin^{2m}\left(\frac{ix_i^2}{\pi}\right)$
- 参数 $m$ 典型的选择是10，控制陡峭度
- 全局最小值与维数相关
- 二维约在(2.20,1.57),  $f(x^*) = -1.8011$





# 几个常见的测试函数



## ◆ Rosenbrock Banana函数

- $f(x) = (a - x_1)^2 - b(x_2 - x_1^2)^2$
- 全局极小点  $(a, a^2)$ ,  $f(x^*) = 0$
- $a = 1, b = 5$ , 极小点为  $(1, 1)$







# 几个常见的测试函数

## ◆ Wheeler函数

➤  $f(x) = -e^{-(x_1x_2-a)^2-(x_2-a)^2}$

➤  $a$  设为 1.5, 在  $(1, -2/3)$  处取得极小值 -1



# 几个常见的测试函数

## ◆ Circle函数

➤  $f(x) = \begin{bmatrix} 1 - r \cos(\theta) \\ 1 - r \sin(\theta) \end{bmatrix}$

➤  $\theta = x_1, r = \frac{1}{2} + \frac{1}{2} \left( \frac{2x_2}{1+x_2^2} \right)$ , Pareto前沿  $r = 1, \text{mod}(\theta, 2\pi) \in [0, \frac{\pi}{2}]$  或者  $r = -1, \text{mod}(\theta, 2\pi) \in [\pi, \frac{3}{2}\pi]$

➤ 多目标测试函数





## 第4章 一维搜索(One-dimensional Search)

◆一元函数求极小及线性搜索均为一维搜索。常用于求：

$$\begin{cases} \min f(x^{(k)} + \lambda d^{(k)}) = \varphi(\lambda) \\ \text{s.t. } \lambda \in S \end{cases}$$

$S$ 有3种情况  $(-\infty, +\infty)$  或  $(0, +\infty)$  或  $[a, b]$

◆缩小区间的精确一维搜索：考虑问题(P)

$$\begin{cases} \min \varphi(\lambda) \\ \text{s.t. } \lambda \in [\alpha, \beta] \end{cases}$$

这里  $\varphi(\lambda): R \rightarrow R$

1、不确定区间及单峰函数

不确定区间:  $[\alpha, \beta]$  含  $\varphi(\lambda)$  的最小点，但不知其位置

# 第4章 一维搜索(One-dimensional Search)



## ◆ 缩小区间的精确一维搜索 (续)

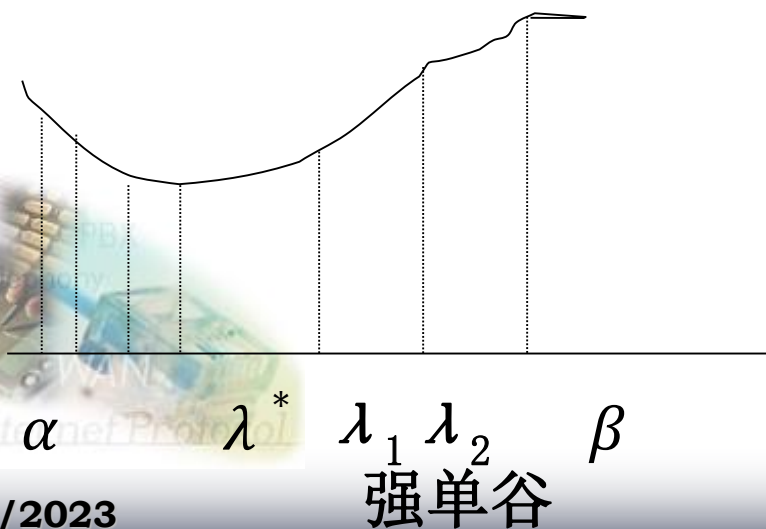
若对任意  $\lambda_1, \lambda_2, \alpha \leq \lambda_1 < \lambda_2 \leq \beta$  满足:

1° 若  $\lambda_2 \leq \lambda^*$ , 则  $\varphi(\lambda_1) > \varphi(\lambda_2)$ ;


2° 若  $\lambda_1 \geq \lambda^*$ , 则  $\varphi(\lambda_1) < \varphi(\lambda_2)$ .

则称  $\varphi(\lambda)$  在  $[\alpha, \beta]$  上强单谷。

若只有当  $\varphi(\lambda_1) \neq \varphi(\lambda^*)$ ,  $\varphi(\lambda_2) \neq \varphi(\lambda^*)$  时, 上述1°, 2° 式才成立, 则称  $\varphi(\lambda)$  在  $[\alpha, \beta]$  上单谷。



强单谷



单谷

# 第4章 一维搜索(One-dimensional Search)





## ◆ 缩小区间的精确一维搜索 (续)

**定理：** 设  $\Phi: R \rightarrow R$  在  $[\alpha, \beta]$  上单谷， $\alpha \leq \lambda < \mu \leq \beta$ ，则有：

1° 若  $\Phi(\lambda) \geq \Phi(\mu)$ ，则  $\Phi(\rho) \geq \Phi(\mu), \forall \rho \in [\alpha, \lambda]$ ；如左下图

2° 若  $\Phi(\lambda) < \Phi(\mu)$ ，则  $\Phi(\rho) \geq \Phi(\lambda), \forall \rho \in [\mu, \beta]$ ；如右下图



# 第4章 一维搜索(One-dimensional Search)



## ◆ 缩小区间的精确一维搜索（续）

证明：1° 反证：设  $\lambda^* \in [\alpha, \beta]$  为最小点,  $\gamma \in [\alpha, \lambda]$  及  $\gamma < \lambda < \lambda^*$ , 使  $\Phi(\gamma) < \Phi(\mu) < \Phi(\lambda)$ ,


➤ 若  $\lambda^* \in [\lambda, \beta]$ , 由定义  $\Phi(\gamma) > \Phi(\lambda)$ , 矛盾（假设）；

➤ 若  $\lambda^* \in [\alpha, \lambda)$ , 由定义及  $\mu > \lambda \geq \lambda^*$ ,  $\Phi(\mu) > \Phi(\lambda)$  矛盾（条件）；

于是结论成立。

2° 的证明类似（略）。

注：上述定理为缩短区间的算法提供了理论根据



# 第4章 一维搜索(One-dimensional Search)



## ◆ 缩小区间的精确一维搜索 (续)

### 2、黄金分割法 (0.618 法)

通过上述定理, 选二点  $\lambda < \mu$ , 比较  $\Phi(\lambda)$  与  $\Phi(\mu)$ , 可去掉  $[\alpha, \lambda]$  或者  $[\mu, \beta]$ . 考虑条件:


1° 对称:  $\lambda - \alpha = \beta - \mu$  .....(1)

使“坏”的情况去掉, 区间长度不小于“好”的情况

2° 保持缩减比:  $t = (\text{保留的区间长度} / \text{原区间长度})$  不变。

使每次保留下来的节点  $\lambda$  或  $\mu$ , 在下一次的比较中成为一个相应比例位置的节点

**推导缩减比  $t$** : 如图设第一次保留  $[\alpha, \mu]$  (去掉  $[\mu, \beta]$ ), 那么第二次保留的长度为  $[\alpha, \lambda]$ , 则



$$t = \frac{\mu - \alpha}{\beta - \alpha} = \frac{\lambda - \alpha}{\mu - \alpha} \dots\dots(2)$$

# 第4章 一维搜索(One-dimensional Search)



## ◆ 缩小区间的精确一维搜索

### 2、黄金分割法 (0.618 法) (续)

整理②：

$$\begin{cases} \mu = \alpha + t(\beta - \alpha) \\ \lambda = \alpha + t(\mu - \alpha) \end{cases}$$

结合①式： $t^2 + t - 1 = 0$

故  $t \approx 0.618$

$$t = \frac{-1 \pm \sqrt{5}}{2} \text{ (舍去负值)}$$

注意 上式有  $t^2 = 1 - t$ , 故有

$$\begin{cases} \mu = \alpha + t(\beta - \alpha) \\ \lambda = \alpha + (1 - t)(\beta - \alpha) \end{cases}$$

算法框图如下



# 第4章 一维搜索(One-dimensional Search)



## ◆ 缩小区间的精确一维搜索 之 黄金分割法 (0.618 法)

初始  $[\alpha, \beta], \varepsilon > 0$   
 $t = (\sqrt{5} - 1) / 2$

$$\lambda = \alpha + (1 - t)(\beta - \alpha)$$
$$\mu = \alpha + t(\beta - \alpha)$$

$\beta - \alpha < \varepsilon?$

yes

STOP;  
 $\lambda^* = (\alpha + \beta) / 2$

No


$\Phi(\lambda) - \Phi(\mu) > 0?$

No

$$\beta = \mu, \mu = \lambda$$
$$\lambda = \alpha + (1 - t)(\beta - \alpha)$$

yes

$$\alpha = \lambda, \lambda = \mu$$
$$\mu = \alpha + t(\beta - \alpha)$$



# 第4章 一维搜索(One-dimensional Search)



◆ 与黄金分割法类似的方法还有Fibonacci法，区别在于搜索区间长度的缩短率不是黄金分割数，而是Fibonacci数，

- $F_1 = F_2 = 1, F_n = F_{n-1} + F_{n-2}, n \geq 3$
- 假设最后满足要求的区间为 $I_n$ ,则倒数第二个区间宽度为 $F_2 I_n$ ,倒数第3个区间宽度为 $F_3 I_n \dots$

$$I_1 = I_2 + I_3 = 8I_5$$

$$I_2 = I_3 + I_4 = 5I_5$$

$$I_3 = I_4 + I_5 = 3I_5$$

$$I_4 = 2I_5$$

$$I_5$$


◆ 缩短率 $b_{k+1} - a_{k+1} = \frac{F_{n-k}}{F_{n-k+1}}(b_k - a_k)$ ,要求 $n$ 次后,  $b_n - a_n \leq \delta$ ,实际上, 当 $n \rightarrow \infty$ ,  
 $\lim_{n \rightarrow \infty} \frac{F_n}{F_{n+1}} = (\sqrt{5}-1)/2$ ;  $b_n - a_n = \frac{1}{F_n}(b_1 - a_1)$ ,选择合适的 $n$ ,使得精度符合要求。

# 第4章 一维搜索(One-dimensional Search)

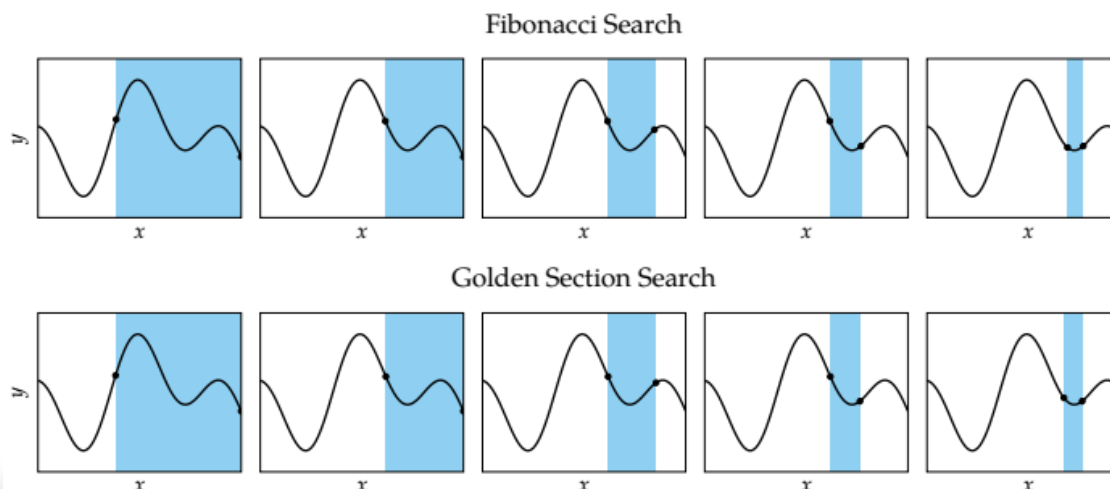


## ◆比较Fibonacci和黄金分割搜索方法

### ➤单模函数



### ➤非单模函数



# 第4章 一维搜索(One-dimensional Search)



## ◆3、中点法(二分法)



设 $\phi(\lambda)$ 在 $[\alpha, \beta]$ 上可微, 且当导数为零时是解。取 $\lambda = (\alpha + \beta) / 2$ , 那么

$\phi'(\lambda) = 0$  时,  $\lambda$ 为最小点,  $\lambda = \lambda^*$  ;

$\phi'(\lambda) > 0$  时,  $\lambda$ 在上升段,  $\lambda^* < \lambda$ , 去掉 $[\lambda, \beta]$  ;

$\phi'(\lambda) < 0$  时,  $\lambda$ 在下降段,  $\lambda^* > \lambda$ , 去掉 $[\alpha, \lambda]$  ;

(算法框图略)



# 第4章 一维搜索(One-dimensional Search)



## 4、进退法求初始不确定区间

找三点使两端点的函数值大于中间点的函数值。

思路：任取 $\lambda_0$ ，步长 $\delta > 0$ ，取 $\lambda_1 = \lambda_0 + \delta$ ，

1° 若 $\Phi(\lambda_0) < \Phi(\lambda_1)$ ，令 $\delta = 2\delta$ （步长加倍）， $\lambda_2 = \lambda_0 - \delta$ ，

$\left\{ \begin{array}{l} \text{若 } \Phi(\lambda_2) < \Phi(\lambda_0), \text{ 则令 } \lambda_1 = \lambda_0, \lambda_0 = \lambda_2, \text{ 重复 } 1^\circ \\ \text{若 } \Phi(\lambda_2) > \Phi(\lambda_0), \text{ 则停, } \alpha = \lambda_2, \beta = \lambda_1 \text{ (图1)} \end{array} \right.$

2° 若 $\Phi(\lambda_0) > \Phi(\lambda_1)$ ，令 $\delta = 2\delta$ ， $\lambda_2 = \lambda_1 + \delta$ ，

$\left\{ \begin{array}{l} \text{若 } \Phi(\lambda_2) < \Phi(\lambda_1), \text{ 则令 } \lambda_0 = \lambda_1, \lambda_1 = \lambda_2, \text{ 重复 } 2^\circ \\ \text{若 } \Phi(\lambda_2) > \Phi(\lambda_1), \text{ 则停, } \alpha = \lambda_0, \beta = \lambda_2 \text{ (图2)} \end{array} \right.$





图1




图2

# 第4章 一维搜索(One-dimensional Search)



## 4、进退法求初始不确定区间（续）

### （自己画算法框图）

#### ◆注意

- $\delta$  选择要适当。（太大含多个单峰区间，太小迭代次数增加）；
- $\Phi(\lambda)$  单调时无结果，(加迭代次数限制)；
- 可与中点法结合寻找单调区间（思考）





## ◆ 牛顿法 (Newton) 和插值法

- 插值法利用插值函数逼近所需求解的目标函数，把插值函数的极小点作为迭代点。常见的有三点二次插值，两点二次插值和三次插值多项式

### 1、Newton法:

对 $\Phi$ 在 $\lambda_k$  点展开:

$$\Phi(\lambda) = \Phi(\lambda_k) + \Phi'(\lambda_k)(\lambda - \lambda_k) + (1/2)\Phi''(\lambda_k)(\lambda - \lambda_k)^2 + O(\lambda - \lambda_k)^2$$

取二次式(略去高阶项):

$$q_k(\lambda) = \Phi(\lambda_k) + \Phi'(\lambda_k)(\lambda - \lambda_k) + \frac{1}{2}\Phi''(\lambda_k)(\lambda - \lambda_k)^2$$





# 第4章 一维搜索-Newton和插值法

## ◆牛顿法（Newton）和插值法

### 1、Newton法：（续）

用 $q_k(\lambda)$ 作为 $\Phi(\lambda)$ 的近似，当 $\Phi''(\lambda_k) > 0$ 时，其驻点为极小点：

$$q'_k(\lambda) = \Phi'(\lambda_k) + \Phi''(\lambda_k)(\lambda - \lambda_k) = 0$$

得  $\lambda_{k+1} = \lambda_k - \Phi'(\lambda_k)/\Phi''(\lambda_k)$

取 $\lambda_{k+1}$ 为新的迭代点。以上过程即Newton法。

**特点：二阶、局部收敛。**

算法框图如下

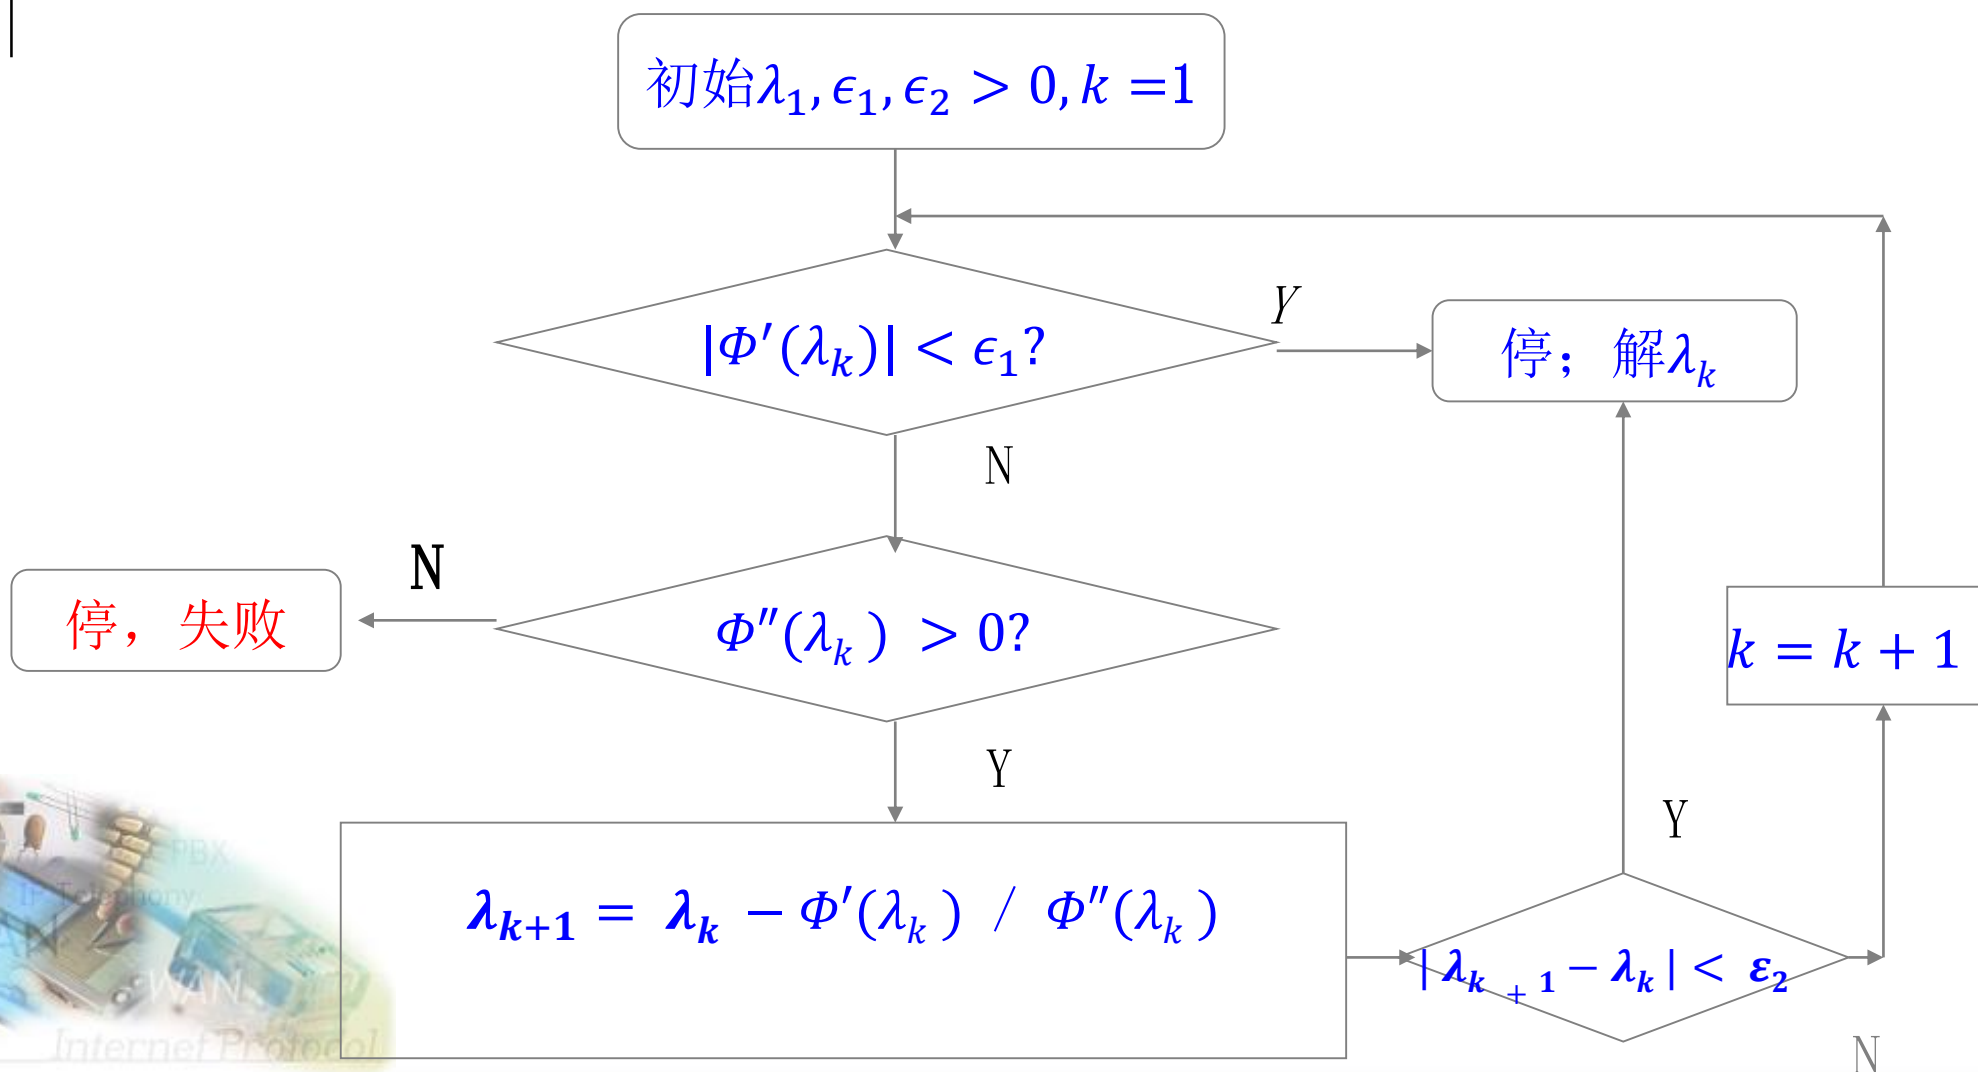




# 第4章 一维搜索-Newton和插值法



## ◆Newton法算法框图:





# 第4章 一维搜索-Newton和插值法

## 二、牛顿法 (Newton) 和插值法

### 1、Newton法: (续)

例. 求  $\min \Phi(\lambda) = \int_0^{\lambda} \arctan t dt$

解:  $\Phi'(\lambda) = \arctan \lambda$ ,  $\Phi''(\lambda) = 1 / (1 + \lambda^2)$

迭代公式:  $\lambda_{k+1} = \lambda_k - (1 + \lambda_k^2) \arctan \lambda_k$

取  $\lambda_1 = 1$ , 计算结果:

$k$	$\lambda_k$	$\Phi'(\lambda_k)$	$1 / \Phi''(\lambda_k)$
1	1	0.7854	2
2	-0.5708	-0.5187	1.3258
3	0.1169	-0.1164	1.0137
4	-0.001095	-0.001095	

$$\lambda_4 \approx \lambda^* = 0$$

取  $\lambda_1 = 2$ , 计算结果如下:



# 第4章 一维搜索-Newton和插值法

## 二、牛顿法 (Newton) 和插值法

### 1、Newton法： (续)

$k$	$\lambda_k$	$\Phi'(\lambda_k)$	$1 / \Phi''(\lambda_k)$
1	2	1.1071	5
2	-3.5357	-1.2952	13.50
3	13.95	不收敛。	

- ◆ 牛顿法的基本思想是在迭代点  $x^{(k)}$  附近用二次函数  $q^{(k)}(s) = f(x^{(k)}) + g_k^T s + \frac{1}{2} s^T G_k s$  来逼近  $f(x)$ , 并以  $q^{(k)}(s)$  的极小点  $s^{(k)}$  来修正  $x^{(k)}$ , 得到  $x^{(k+1)} = x^{(k)} + s^{(k)}$





# 第4章 一维搜索-Newton和插值法

## 二、牛顿法 (Newton) 和插值法

### 1、Newton法： (续)

$k$	$\lambda_k$	$\Phi'(\lambda_k)$	$1 / \Phi''(\lambda_k)$
1	2	1.1071	5
2	-3.5357	-1.2952	13.50
3	13.95	不收敛	

### 2、插值法：

用  $\phi(\lambda)$  在 2 或 3 个点的函数值或导数值，构造 2 次或 3 次多项式作为  $\phi(\lambda)$  的近似值，以这多项式的极小点为新的迭代点

3点2次，2点2次，4点3次，3点3次，2点3次等

以3点2次为例：

取  $\lambda_1, \lambda_2, \lambda_3$ ，求出  $\phi(\lambda_1), \phi(\lambda_2), \phi(\lambda_3)$



# 第4章 一维搜索-Newton和插值法

## ◆ 牛顿法 (Newton) 和插值法

### 2、插值法：（续）


设二次插值多项式： $a\lambda^2 + b\lambda + c = \phi(\lambda)$

$$\begin{cases} a\lambda_1^2 + b\lambda_1 + c = \phi(\lambda_1) \\ a\lambda_2^2 + b\lambda_2 + c = \phi(\lambda_2) \\ a\lambda_3^2 + b\lambda_3 + c = \phi(\lambda_3) \end{cases} \quad \text{解得 } a, b$$

$$a = - \frac{(\lambda_1 - \lambda_2)\Phi(\lambda_3) + (\lambda_2 - \lambda_3)\Phi(\lambda_1) + (\lambda_3 - \lambda_1)\Phi(\lambda_2)}{(\lambda_1 - \lambda_2)(\lambda_2 - \lambda_3)(\lambda_3 - \lambda_1)}$$

$$b = \frac{(\lambda_1^2 - \lambda_2^2)\Phi(\lambda_3) + (\lambda_2^2 - \lambda_3^2)\Phi(\lambda_1) + (\lambda_3^2 - \lambda_1^2)\Phi(\lambda_2)}{(\lambda_1 - \lambda_2)(\lambda_2 - \lambda_3)(\lambda_3 - \lambda_1)}$$

$$\bar{\lambda} = - \frac{b}{2a}$$



# 第4章 一维搜索-Newton和插值法




## ◆ 2、插值法：（续）

- 上述及得4个已知点，设为 $\lambda_0, \bar{\lambda}, \lambda_1, \lambda_2$ ，然后从中舍去一个，保证最小点在区间内
- 怎么保证？初始三点如何选取？

## ◆ 两点两次

- 两点 $\lambda_0, \lambda_1$ 函数值及一点的导数值， $\psi(\lambda) = a\lambda^2 + b\lambda + c$ ，从而可得



复这个过程

- 特点：简单，不必预先确定上下界，但函数单调时得不到结果

# 第4章 一维搜索-Newton和插值法



## ◆三次插值：四个参数

- 因此需要四个条件：可以是四个点，3点加一点的导数值，2点加两点导数值

## ◆实用中，特别对单变量问题求最小点时，利用上面的方法相互配合，会收到较好的结果

## ◆总体来说，精确一维搜索需要花费很大的工作量，特别是当迭代点远离问题的解的时候，精确求解一个一维子问题通常不是十分有效

## ◆实际上，牛顿法和拟牛顿法的收敛速度并不依赖于精确一维搜索，因此只要保证目标函数值每一步都有满意的下降，这样可以大大节省工作量


## ◆上述方法一般都收敛到局部极小点，而无法收敛到全局极小点

# 第4章 一维搜索-Shubert-Piyavskii方法



- ◆ 能收敛到全局极小点
- ◆ 如果函数是Lipschitz连续：即导数的幅度存在上界
  - $|f(x) - f(y)| \leq l|x - y|, \forall x, y \in [a, b]$ , 可推广到向量和范数
  - 给定点 $(x_0, f(x_0))$ , 若 $x > x_0$ , 直线 $f(x_0) - l(x - x_0)$ ;  $x < x_0, f(x_0) + l(x - x_0)$ 形成函数 $f$ 的下界
- ◆ 给定李普希兹常数 $l$ , 算法从中点 $x^{(1)} = \frac{a+b}{2}$ , 通过该点斜率为 $\pm l$ 的直线构造 $f$ 的锯齿样下界。如果常数 $l$ 有效, 这些直线总是在函数 $f$ 的下面

一步步构建  
函数的下界






# 第4章 一维搜索-Shubert-Piyavskii方法



## ◆Shubert-Piyavskii

- 算法在最小的锯齿点  $(x^{(n)}, y^{(n)})$  与该点的函数值  $f(x^{(n)})$  之差小于某个小常数的时候停止
- $y^{(n)} - f(x^{(n)}) < \epsilon$

不断迭代找到锯齿线的最小值点，并计算改点的函数值来更新锯齿



- 每次迭代中，最小值所在的不确定区域计算为：

- $\left[ x^{(i)} - \frac{1}{l} (f(x_{min}) - y^{(i)}), x^{(i)} + \frac{1}{l} (y^{(i)} - y_{min}) \right]$

这里  $(x^{(i)}, y^{(i)})$  为下锯齿顶点， $(x_{min}, y_{min})$  为最小的上锯齿顶点

- 只有当  $y^{(i)} < y_{min}$  时，这个点对确定区域有贡献

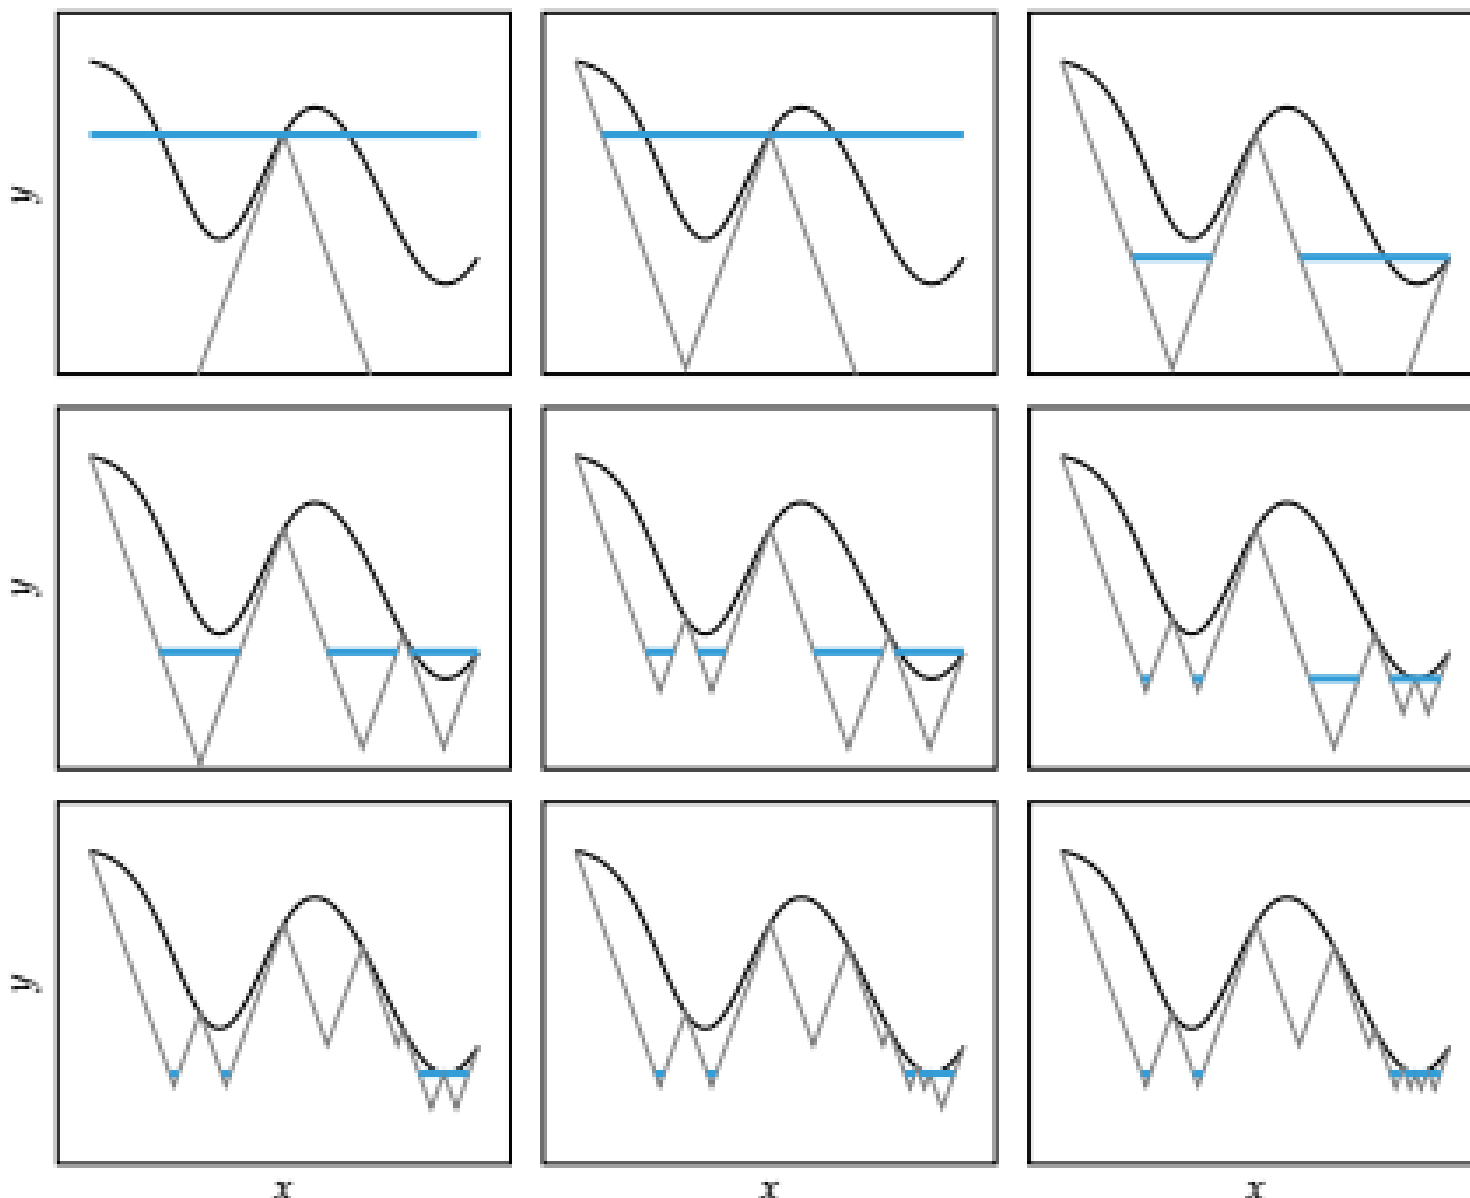
# 第4章 一维搜索-Shubert-Piyavskii方法



◆例子

◆缺点？

要求李普希兹常数  $L$ ，  
越大下界越差





## 第4章 一维搜索-不精确搜索

◆ 下降方向法  $x^{(k+1)} = x^{(k)} + \lambda d^{(k)}$ , 确定方向后, 需要计算步长

- 大步长收敛快, 但可能错过最优值
- 小步长收敛慢
- 固定步长有时称为学习率
- 或者使用  $\lambda_k = \lambda_1 \gamma^{k-1}$ ,  $\gamma \in (0, 1)$  这样的衰减步长因子
- 是否还有别的方法?





## 第4章 一维搜索-不精确搜索

### ◆不精确一维搜索： $\min f(x)$

考虑从 $x^{(k)}$ 点出发，沿方向 $d^{(k)}$ 寻找新迭代点： $x^{(k)} + \lambda_k d^{(k)}$

要求：1°  $f(x^{(k)} + \lambda_k d^{(k)}) < f(x^{(k)})$ ;

2°  $\lambda_k > 0$ 不能太小。

总体希望收敛快，每一步不要求达到精确最小，速度快，随着步数增加，则整个过程达到收敛。

### ◆Goldstein法：是一个实用方法

➤ 设  $f: R^n \rightarrow R$ 。在 $x$ 取方向 $d$ ，有  $\nabla f^T(x)d < 0$  (即 $d$ 为下降方向)，令  $s^{(k)} = x^{(k+1)} - x^{(k)} = \lambda_k d^{(k)}$  求 $\lambda$ 使

$$(1) f(x^{(k+1)}) - f(x^{(k)}) \leq \rho \nabla f^T(x^{(k)}) s^{(k)}$$


$$(2) f(x^{(k+1)}) - f(x^{(k)}) \geq (1 - \rho) \nabla f^T(x^{(k)}) s^{(k)}$$

其中  $\rho \in (0, \frac{1}{2})$ ，实际中常取  $\rho = 0.1$  或更小

思考这两个条件的意义？

# 第4章 一维搜索-不精确搜索

## ◆不精确一维搜索(续)



$$(1) f(x^{(k+1)}) - f(x^{(k)}) \leq \rho \nabla f^T(x^{(k)}) s^{(k)}$$

$$(2) f(x^{(k+1)}) - f(x^{(k)}) \geq (1 - \rho) \nabla f^T(x^{(k)}) s^{(k)}$$

$$y = f(x^{(k)}) + \rho \nabla f^T(x^{(k)}) d^{(k)} \lambda$$

$$f(x^{(k)} + \lambda d^{(k)})$$

可接受范围


可接受范围

$\lambda$

$$y = f(x^{(k)}) + (1 - \rho) \nabla f^T(x^{(k)}) d^{(k)} \lambda$$

◆经常在牛顿类方法中使用，但不太适合拟牛顿方法

## ◆七次线搜索





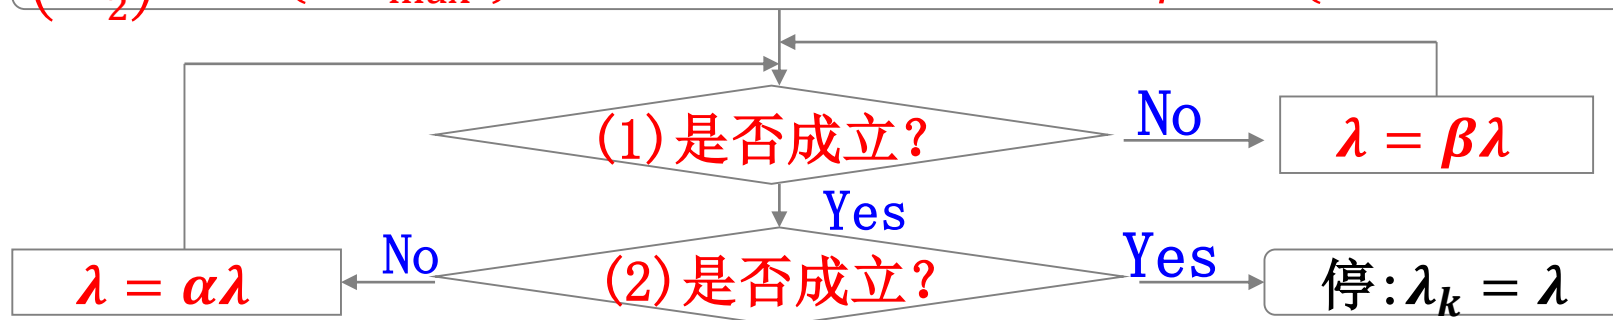
## 第4章 一维搜索-不精确搜索

$$(1) f(x^{(k+1)}) - f(x^{(k)}) \leq \rho \nabla f^T(x^{(k)}) s^{(k)}$$

$$(2) f(x^{(k+1)}) - f(x^{(k)}) \geq (1 - \rho) \nabla f^T(x^{(k)}) s^{(k)}$$

### ◆ 不精确一维搜索(续)

$\rho \in \left(0, \frac{1}{2}\right), \lambda \in (0, \lambda_{\max}), \alpha > 1$  (步长增大系数),  $\beta < 1$  (步长缩短系数)



◆ 一般 $\alpha, \beta$ 的选择要适当, 一般选取 $\alpha = 1.5, \beta = 0.5$ , 一般情况下迭代几步就可得到解, 利用这种不精确一维搜索, 不少算法可以得到全局收敛性结果

◆ 1966年, Armijo给出与Goldstein法类似的不精确一维搜索规则, 相当于替换(2)中的 $(1 - \rho) \rightarrow \mu\rho, \mu$ 取5-10

◆ 1967年, Goldstein提出更一般的方法, 把(2)式改为:

$$f(x^{(k+1)}) \geq f(x^{(k)}) + \sigma \nabla f^T(x^{(k)}) s^{(k)}, \text{其中 } \sigma \in (\rho, 1)$$

## ◆ Wolfe-Powell方法(1969,1976)

➤ 前面Goldstein方法中规则(2)改为对导数的要求

✓ (WP规则1)  $f(x^{(k+1)}) \leq f(x^{(k)}) + \rho \nabla f^T(x^{(k)})s^{(k)}$

✓ (WP规则2)  $\nabla f^T(x^{(k+1)})s^{(k)} \geq \sigma \nabla f^T(x^{(k)})s^{(k)}$

➤ 其中  $\rho \in (0, \frac{1}{2})$ ,  $\sigma \in (\rho, 1)$

◆ WP规则(1)的意义如前

◆ WP规则(2)的意义?


➤ 表示要求在  $x^{(k+1)}$  点对应的斜率不小于  $\sigma \nabla f^T(x^{(k)})d^{(k)}$





# 第4章 一维搜索-不精确搜索

## ◆ 图示





## 第4章 一维搜索-不精确搜索

### ◆ Wolfe-Powell方法(1969,1976)

- **(WP规则1)**  $f(x^{(k+1)}) \leq f(x^{(k)}) + \rho \nabla f^T(x^{(k)})s^{(k)}$
- **(WP规则2)**  $\nabla f^T(x^{(k+1)})s^{(k)} \geq \sigma \nabla f^T(x^{(k)})s^{(k)}$
- 其中  $\rho \in (0, \frac{1}{2})$ ,  $\sigma \in (\rho, 1)$

- ◆ 算法步骤如Goldstein类似，一般以 $\lambda = 1$ 优先
- ◆ 此方法实算时，平均只需要2-3次函数值计算即可求得 $\lambda_k$ ,对提高整体速度很有效。这个方法用于某些多变量算法中的线性搜索可得全局收敛性结果
- ◆ 如果需要较高的精度时，**WP规则(2)**可进一步改为：

$$\textbf{(WP改进规则2)} |\nabla f^T(x^{(k+1)})d^{(k)}| \leq -\eta \nabla f^T(x^{(k)})d^{(k)}, \eta \in (0, 1)$$

- ◆ 显然当 $\eta = 0$ ,此即为精确一维搜索，但该方法不需要预先求出不确定区间，使用较为方便，又便于通过调整 $\eta$ 来调整精确度要求，因而也常当做近似的精确一维搜索使用。当 $\eta = 0.1$ 时，就可以看做近似的精确一维搜索
- ◆ 在绝大多数线搜索方法中使用，尤其适合拟牛顿方法



### ◆ 足够下降和回溯 (Backtracking) 方法

➤ 一般来说, 目标函数值的充分下降并不能保证算法沿搜索方向有合理的进展, 但如果线索搜通过采用所谓的 backtracking 方法可以获得合适的候选步长, 也可以达到目标

➤ 算法如下 (backtracking 线搜索) :

选择  $\alpha_0 > 0, \rho \in (0, 1), c \in (0, 1)$ ; 令  $\alpha \leftarrow \alpha_0$ ;

Repeat until  $f(x^{(k)} + \alpha p_k) \leq f(x^{(k)}) + c\alpha \nabla f_k^T p_k$

$\alpha \leftarrow \rho\alpha$ ;

End(repeat)

终止令  $\alpha_k = \alpha$ .

✓ 初始步长  $\alpha_0$  在牛顿和拟牛顿方法中设为1, 但在最速下降或共轭梯度中采用别的值,  $\rho$  值在迭代中可以变化, 例如  $0 < \rho_{low} < \rho < \rho_{high} < 1$

✓ 方法比较适合牛顿法, 但不太适合拟牛顿和共轭梯度法



# 第4章 一维搜索-不精确搜索

## ◆ Zoutendijk定理

- 优化中的迭代步骤中，方向 $p_k$ 为下降方向， $\alpha_k$ 满足Wolfe条件（别的条件也都可以）。假设 $f$ 在 $R^n$ 上下有界并在包含水平集 $L = \{x: f(x) < f(x^{(0)})\}$ 的开集 $N$ 上连续可微， $x^{(0)}$ 为迭代初始点，并假设 $\nabla f$ 在 $N$ 上是Lipschitz连续的，即：

$$\|\nabla f(x) - \nabla f(\tilde{x})\| \leq L\|x - \tilde{x}\|, \forall x, \tilde{x} \in N$$

- 则有： $\sum_{k \geq 0} \cos^2 \theta_k \|\nabla f_k\|^2 < \infty$ ---**zoutendijk条件**

- 注意： $\cos \theta_k = \frac{-\nabla f_k^T p_k}{\|\nabla f_k\| \|p_k\|}$

- Lipschitz连续一般由平滑性假设都可以获得，因此在实际问题中一般都满足。由zoutendijk条件意味着 $\cos^2 \theta_k \|\nabla f_k\|^2 \rightarrow 0$ ，如果角度满足 $\cos \theta_k \geq \delta > 0, \forall k$ ，则立得： $\lim_{k \rightarrow \infty} \|\nabla f_k\| = 0$

- 在拟牛顿方法中， $p_k = -B_k \nabla f_k$ ，若正定矩阵 $\|B_k\| \|B_k^{-1}\| \leq M, \forall k$ ，则有 $\cos \theta_k \geq \frac{1}{M}$ ，利用zoutendijk条件，则有 $\lim_{k \rightarrow \infty} \|\nabla f_k\| = 0$ ，意味着满足Wolfe条件的牛顿和拟牛顿方法，其偏转矩阵正定，具有有界条件数，则其全局收敛

# 第4章 一维搜索-最速下降法的收敛速率



- ◆ 对对称正定二次函数  $f(x) = \frac{1}{2}x^T Qx - b^T x + c$  应用最速下降法则有：

$$x^{(k+1)} = x^{(k)} - \left( \frac{\nabla f_k^T \nabla f_k}{\nabla f_k^T Q \nabla f_k} \right) \nabla f_k$$

- ◆ 令  $\|x\|_Q^2 = x^T Qx$ , 则  $\frac{1}{2}\|x - x^*\|_Q^2 = f(x) - f(x^*)$ -----误差范数,

$$\frac{1}{2}\|x - x^*\|_Q^2 = \left\{ 1 - \frac{(\nabla f_k^T \nabla f_k)^2}{(\nabla f_k^T Q \nabla f_k)(\nabla f_k^T Q^{-1} \nabla f_k)} \right\} \|x^{(k)} - x^*\|_Q^2$$

- ◆ 定理：当上述精确线搜索用于强凸二次函数时，其误差范数满足：

$$\|x^{(k+1)} - x^*\|_Q^2 \leq \left( \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^2 \|x^{(k)} - x^*\|_Q^2$$

- ◆ 这里  $\lambda_n \geq \lambda_{n-1} \geq \dots \geq \lambda_2 \geq \lambda_1 > 0$  为  $Q$  的特征值

# 第4章 一维搜索-最速下降法的收敛速率



- ◆ 假设函数  $f: R^n \rightarrow R$  是连续二次可微，精确线索搜的最速下降法收敛到点  $x^*$ ，该点的Hessian矩阵  $\nabla^2 f(x^*)$  正定。令  $r \in \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}, 1\right)$ ，这里  $\lambda_n \geq \lambda_{n-1} \geq \dots \geq \lambda_2 \geq \lambda_1 > 0$  为  $\nabla^2 f(x^*)$  的特征值，则对足够大的  $k$ ，有：
- ◆  $f(x^{(k+1)}) - f(x^*) \leq r^2 [f(x^{(k)}) - f(x^*)]$
- ◆ 因此，一般不能期望非精确线索搜能改进收敛速度。即使其二阶Hessian矩阵具有良好的性质，例如条件数，也不能保证其快速收敛！
- ◆ 实际上，如何设计快速的能收敛的算法，一直是优化中的重点和难点！





# 第4章 一维搜索-结束

## ◆一维搜索

### ◆精确一维搜索

#### ➤没有利用导数信息

✓黄金分割方法

✓斐波那契方法

#### ➤利用导数信息

✓Newton法

✓插值法

### ◆近似一维搜索

#### ➤Goldstein法、Armijo

#### ➤Wolfe-Powell方法

✓一般2-3步找到

