

谱嵌入与拓扑结构

刘家锋

哈尔滨工业大学

谱嵌入与拓扑结构

- 1 谱嵌入方法
- 2 拓扑结构与近邻图
- 3 流形上的拉普拉斯算子

谱嵌入方法

线性方法

● 子空间与线性流形

- 子空间：令 W 为线性空间 V 的非空子集，如果 W 满足

1. $\forall \mathbf{x}, \mathbf{y} \in W$, 有 $\mathbf{x} + \mathbf{y} \in W$
2. $\forall \mathbf{x} \in W, \alpha \in R$, 有 $\alpha \mathbf{x} \in W$

则称 W 为 V 的线性子空间

- 线性流形：若 W 为 V 的线性子空间， $\boldsymbol{\mu} \in V$ ，则 $W + \boldsymbol{\mu}$ 称为 V 的线性子流形

● 子空间学习


- 假设样本 \mathbf{x} 分布在一个嵌入在 R^m 中的 m' 维子空间
- m' 维子空间由基矢量 $\mathbf{W} = (\mathbf{w}_1, \dots, \mathbf{w}_{m'})$ 所张成
- 样本 \mathbf{x} 在 m' 维子空间上的投影：

$$\mathbf{y} = \mathbf{W}^t \mathbf{x}$$

主成分分析

Algorithm 1 PCA: Principal Component Analysis

- 1: 输入样本集合 D ，计算均值矢量 $\boldsymbol{\mu}$ 和协方差矩阵 $\boldsymbol{\Sigma}$
- 2: 计算矩阵 $\boldsymbol{\Sigma}$ 的特征值和特征矢量，特征值由大到小排序
- 3: 选择前 m' 个特征矢量作为列矢量，构成矩阵 $\mathbf{W} = (\mathbf{w}_1, \dots, \mathbf{w}_{m'})$
- 4: m 维特征矢量 \mathbf{x} 可以转换为 m' 维矢量: $\mathbf{y} = \mathbf{W}^t(\mathbf{x} - \boldsymbol{\mu})$




线性判别分析

Algorithm 2 LDA: Linear Discriminant Analysis

- 1: 计算类间和类内散布矩阵 \mathbf{S}_b 和 \mathbf{S}_w
 - 2: 计算矩阵 $\mathbf{S}_w^{-1}\mathbf{S}_b$ 的特征值和特征矢量，特征值由大到小排序
 - 3: 选择前 m' 个特征矢量作为列矢量，构成矩阵 $\mathbf{W} = (\mathbf{w}_1, \dots, \mathbf{w}_{m'})$
 - 4: m 维特征矢量 \mathbf{x} 可以转换为 m' 维矢量: $\mathbf{y} = \mathbf{W}^t \mathbf{x}$
-

$$\mathbf{S}_w = \sum_i^c \sum_{\mathbf{x} \in D_i} (\mathbf{x} - \boldsymbol{\mu}_i)(\mathbf{x} - \boldsymbol{\mu}_i)^t$$

$$\mathbf{S}_b = \sum_{i=1}^c n_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^t$$




流形学习的谱方法

● 流形学习的谱嵌入框架

- 很多流形学习方法可以采用统一的框架来描述和求解
- 在统一的框架下，可以设计出新的流形学习方法

● 基本思路

- 计算 R^m 空间样本 $\mathbf{x}_i, \mathbf{x}_j$ 之间的相似度 a_{ij} ，构造相似图
- 保持降维到 $R^{m'}$ 维空间之后，样本 $\mathbf{y}_i, \mathbf{y}_j$ 之间的相似度
- 同时，满足与问题相关的某种约束条件



谱嵌入框架(Spectral Embedding)

降维之后的样本矩阵:

$$\mathbf{Y} = (\mathbf{y}_1, \dots, \mathbf{y}_n) = \begin{pmatrix} \tilde{\mathbf{y}}_1^t \\ \vdots \\ \tilde{\mathbf{y}}_{m'}^t \end{pmatrix} = \begin{pmatrix} y_{11} & \cdots & y_{n1} \\ \vdots & \ddots & \vdots \\ y_{1m'} & \cdots & y_{nm'} \end{pmatrix}$$

其中, 矢量 $\tilde{\mathbf{y}}_k$ 由所有降维样本第 k 维特征构成。

相似图的相似矩阵和Laplacian矩阵:

$$\mathbf{A} = (a_{ij}), \quad \mathbf{L} = \mathbf{D} - \mathbf{A}$$

谱嵌入优化目标

保持降维之后样本之间的相似性：

$$\min_{\mathbf{Y}} \frac{1}{2} \sum_{i \neq j} a_{ij} \|\mathbf{y}_i - \mathbf{y}_j\|^2$$

目标函数转化为：

$$\begin{aligned} \sum_{i \neq j} a_{ij} \|\mathbf{y}_i - \mathbf{y}_j\|^2 &= \sum_{i \neq j} a_{ij} \sum_{k=1}^{m'} (y_{ik} - y_{jk})^2 \\ &= \sum_{k=1}^{m'} \sum_{i \neq j} a_{ij} (y_{ik} - y_{jk})^2 \\ &= \sum_{k=1}^{m'} \tilde{\mathbf{y}}_k^t \mathbf{L} \tilde{\mathbf{y}}_k \end{aligned}$$

谱嵌入框架(Spectral Embedding)

谱嵌入的优化问题

$$\min_{\mathbf{Y}} \sum_{k=1}^{m'} \tilde{\mathbf{y}}_k^t \mathbf{L} \tilde{\mathbf{y}}_k$$

subject to

$$\tilde{\mathbf{y}}_k^t \mathbf{B} \tilde{\mathbf{y}}_k = d, \quad k = 1, \dots, m'$$

具体的流形学习方法采用不同的相似图的Laplacian矩阵 \mathbf{L} ，不同的约束矩阵 \mathbf{B}

子空间学习的谱嵌入

构造线性降维映射：

$$\mathbf{y}_i = \mathbf{W}^t \mathbf{x}_i, \quad i = 1, \dots, n$$

$\mathbf{W} = (\mathbf{w}_1, \dots, \mathbf{w}_{m'})$ 为变换矩阵，构造样本矩阵 $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_n)$

$$\mathbf{Y} = (\mathbf{y}_1, \dots, \mathbf{y}_n) = (\mathbf{W}^t \mathbf{x}_1, \dots, \mathbf{W}^t \mathbf{x}_n) = \mathbf{W}^t \mathbf{X}$$

同时

$$\mathbf{Y} = \begin{pmatrix} \tilde{\mathbf{y}}_1^t \\ \vdots \\ \tilde{\mathbf{y}}_{m'}^t \end{pmatrix} = \begin{pmatrix} \mathbf{w}_1^t \\ \vdots \\ \mathbf{w}_{m'}^t \end{pmatrix} \mathbf{X} = \begin{pmatrix} \mathbf{w}_1^t \mathbf{X} \\ \vdots \\ \mathbf{w}_{m'}^t \mathbf{X} \end{pmatrix}$$

因此：

$$\tilde{\mathbf{y}}_k = \mathbf{X}^t \mathbf{w}_k, \quad k = 1, \dots, m'$$

子空间学习的谱嵌入

子空间学习谱嵌入的优化问题：

$$\min_{\mathbf{W}} \sum_{k=1}^{m'} \tilde{\mathbf{y}}_k^t \mathbf{L} \tilde{\mathbf{y}}_k = \sum_{k=1}^{m'} \mathbf{w}_k^t \mathbf{X} \mathbf{L} \mathbf{X}^t \mathbf{w}_k$$

subject to

$$\mathbf{w}_k^t \mathbf{X} \mathbf{B} \mathbf{X}^t \mathbf{w}_k = d, \quad k = 1, \dots, m'$$

问题的解为广义特征值问题

$$(\mathbf{X} \mathbf{L} \mathbf{X}^t) \mathbf{w} = \lambda (\mathbf{X} \mathbf{B} \mathbf{X}^t) \mathbf{w}$$

最小 m' 个特征值对应的特征矢量

谱嵌入框架的意义

- 从谱嵌入的角度理解流形学习方法
 - 在谱嵌入的框架下分析传统的流形学习方法
 - 考察传统方法对应的相似图和约束图
- 设计新的流形学习方法
 - 根据需要，可以设计不同的相似图构造方法，得到新的流形学习方法
 - 不同相似性度量，不同的图结构对应不同的相似图

谱嵌入框架下的PCA

PCA的优化问题：将基矢量的最大值优化转换为最小值优化

$$\min_{\mathbf{W}} \sum_{k=1}^{m'} \mathbf{w}_k^t \mathbf{\Sigma} \mathbf{w}_k$$

subject to

$$\mathbf{w}_k^t \mathbf{w}_k = 1, \quad k = 1, \dots, m'$$

定义样本矩阵 \mathbf{X} 和矢量 \mathbf{e} :

$$\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_n), \quad \mathbf{e} = (1, \dots, 1)^t$$

样本的均值可以表示为:

$$\boldsymbol{\mu} = \frac{1}{n} \mathbf{X} \mathbf{e} = \frac{1}{n} (\mathbf{x}_1, \dots, \mathbf{x}_n) \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

谱嵌入框架下的PCA

协方差矩阵可以写成：

$$\begin{aligned}
 \Sigma &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^t \\
 &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^t - \boldsymbol{\mu} \boldsymbol{\mu}^t \\
 &= \frac{1}{n} (\mathbf{x}_1, \dots, \mathbf{x}_n) \begin{pmatrix} \mathbf{x}_1^t \\ \vdots \\ \mathbf{x}_n^t \end{pmatrix} - \left(\frac{1}{n} \mathbf{X} \mathbf{e} \right) \left(\frac{1}{n} \mathbf{X} \mathbf{e} \right)^t \\
 &= \frac{1}{n} \mathbf{X} \mathbf{X}^t - \frac{1}{n^2} \mathbf{X} \mathbf{e} \mathbf{e}^t \mathbf{X}^t \\
 &= \frac{1}{n} \mathbf{X} \left(\mathbf{I} - \frac{1}{n} \mathbf{e} \mathbf{e}^t \right) \mathbf{X}^t
 \end{aligned}$$

谱嵌入框架下的PCA

如果令：

$$\mathbf{L} = \mathbf{I} - \frac{1}{n} \mathbf{e} \mathbf{e}^t$$

PCA的优化问题可以表示为谱嵌入框架一致的形式：

$$\min_{\mathbf{W}} \sum_{k=1}^{m'} \mathbf{w}_k^t \mathbf{X} \mathbf{L} \mathbf{X}^t \mathbf{w}_k$$

subject to

$$\mathbf{w}_k^t \mathbf{w}_k = 1, \quad k = 1, \dots, m'$$

PCA的相似图

令：

$$\mathbf{A} = \frac{1}{n} \mathbf{e} \mathbf{e}^t = \begin{pmatrix} \frac{1}{n} & \cdots & \frac{1}{n} \\ \vdots & \ddots & \vdots \\ \frac{1}{n} & \cdots & \frac{1}{n} \end{pmatrix}$$

对角矩阵：


$$\mathbf{D} = \text{diag} \left(\sum_{j=1}^n a_{ij} \right) = \mathbf{I}$$

可见矩阵 \mathbf{L} 为Laplacian矩阵：

$$\mathbf{L} = \mathbf{I} - \frac{1}{n} \mathbf{e} \mathbf{e}^t = \mathbf{D} - \mathbf{A}$$

PCA的相似图

矩阵 \mathbf{A} 为PCA的相似矩阵，对应的相似图为全连接图，任意两个样本之间的相似度为 $\frac{1}{n}$



谱嵌入框架下的LDA

LDA的优化目标是Rayleigh商：

$$\min_{\mathbf{w}} \frac{\mathbf{w}^t \mathbf{S}_w \mathbf{w}}{\mathbf{w}^t \mathbf{S}_b \mathbf{w}}$$

可以证明，类间散布 \mathbf{S}_b 与类内散布 \mathbf{S}_w 之间满足：

$$\mathbf{S}_b = \sum_{j=1}^c n_j (\boldsymbol{\mu}_j - \boldsymbol{\mu})(\boldsymbol{\mu}_j - \boldsymbol{\mu})^t = n\boldsymbol{\Sigma} - \mathbf{S}_w$$

因此：

$$\frac{\mathbf{w}^t \mathbf{S}_b \mathbf{w}}{\mathbf{w}^t \mathbf{S}_w \mathbf{w}} = \frac{n\mathbf{w}^t \boldsymbol{\Sigma} \mathbf{w} - \mathbf{w}^t \mathbf{S}_w \mathbf{w}}{\mathbf{w}^t \mathbf{S}_w \mathbf{w}} = n \frac{\mathbf{w}^t \boldsymbol{\Sigma} \mathbf{w}}{\mathbf{w}^t \mathbf{S}_w \mathbf{w}} - 1$$

Rayleigh商的优化等价于：

$$\min_{\mathbf{w}} \frac{\mathbf{w}^t \mathbf{S}_w \mathbf{w}}{\mathbf{w}^t \mathbf{S}_b \mathbf{w}} \iff \min_{\mathbf{w}} \frac{\mathbf{w}^t \mathbf{S}_w \mathbf{w}}{\mathbf{w}^t \boldsymbol{\Sigma} \mathbf{w}}$$

谱嵌入框架下的LDA

Rayleigh商优化转化为条件优化问题：

$$\min_{\mathbf{W}} \sum_{k=1}^{m'} \mathbf{w}_k^t \mathbf{S}_w \mathbf{w}_k$$

subject to

$$\mathbf{w}_k^t \mathbf{\Sigma} \mathbf{w}_k = d, \quad k = 1, \dots, m'$$

谱嵌入框架下的LDA

定义 n 维指示矢量 \mathbf{e}_j ，第 i 维元素指示样本 \mathbf{x}_i 是否属于类别 ω_j ：

$$e_{ji} = \begin{cases} 1, & \mathbf{x}_i \in \omega_j \\ 0, & \text{otherwise} \end{cases}$$

样本 \mathbf{x}_i 属于且仅属于 $\omega_1, \dots, \omega_c$ 中的一个类别，因此：

$$\sum_{j=1}^c e_{ji} = 1$$

类别 ω_j 中的样本数：

$$n_j = \sum_{i=1}^n e_{ji}$$

谱嵌入框架下的LDA

ω_j 类的样本均值:

$$\boldsymbol{\mu}_j = \frac{1}{n_j} \sum_{i=1}^n e_{ji} \mathbf{x}_i = \frac{1}{n_j} (\mathbf{x}_1, \dots, \mathbf{x}_n) \mathbf{e}_j = \frac{1}{n_j} \mathbf{X} \mathbf{e}_j$$

总的类内散布矩阵:

$$\begin{aligned} \mathbf{S}_w &= \sum_{j=1}^c \sum_{i=1}^n e_{ji} (\mathbf{x}_i - \boldsymbol{\mu}_j) (\mathbf{x}_i - \boldsymbol{\mu}_j)^t \\ &= \sum_{j=1}^c \left[\sum_{i=1}^n e_{ji} \mathbf{x}_i \mathbf{x}_i^t - \sum_{i=1}^n e_{ji} \boldsymbol{\mu}_j \boldsymbol{\mu}_j^t \right] \\ &= \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^t - \sum_{j=1}^c n_j \boldsymbol{\mu}_j \boldsymbol{\mu}_j^t \\ &= \mathbf{X} \mathbf{X}^t - \sum_{j=1}^c \frac{1}{n_j} (\mathbf{X} \mathbf{e}_j) (\mathbf{X} \mathbf{e}_j)^t = \mathbf{X} \left(\mathbf{I} - \sum_{j=1}^c \frac{1}{n_j} \mathbf{e}_j \mathbf{e}_j^t \right) \mathbf{X}^t \end{aligned}$$

谱嵌入框架下的LDA

定义矩阵:

$$\mathbf{L}_{\text{LDA}} = \mathbf{I} - \sum_{j=1}^c \frac{1}{n_j} \mathbf{e}_j \mathbf{e}_j^t, \quad \mathbf{L}_{\text{PCA}} = \mathbf{I} - \frac{1}{n} \mathbf{e} \mathbf{e}^t$$

LDA的优化问题可以表示为谱嵌入框架一致的形式:

$$\min_{\mathbf{W}} \sum_{k=1}^{m'} \mathbf{w}_k^t \mathbf{X} \mathbf{L}_{\text{LDA}} \mathbf{X}^t \mathbf{w}_k$$

subject to

$$\mathbf{w}_k^t \mathbf{X} \mathbf{L}_{\text{PCA}} \mathbf{X}^t \mathbf{w}_k = d, \quad k = 1, \dots, m'$$

LDA的相似图

令：

$$\mathbf{A}_{\text{LDA}} = \sum_{j=1}^c \frac{1}{n_j} \mathbf{e}_j \mathbf{e}_j^t, \quad \text{其中元素: } a_{ik} = \sum_{j=1}^c \frac{1}{n_j} e_{ji} e_{jk}$$

矩阵 \mathbf{A}_{LDA} 的第 i 行求和：

$$d_i = \sum_{k=1}^n a_{ik} = \sum_{k=1}^n \sum_{j=1}^c \frac{1}{n_j} e_{ji} e_{jk} = \sum_{j=1}^c \frac{1}{n_j} e_{ji} \sum_{k=1}^n e_{jk} = \sum_{j=1}^c e_{ji} = 1$$

因此：

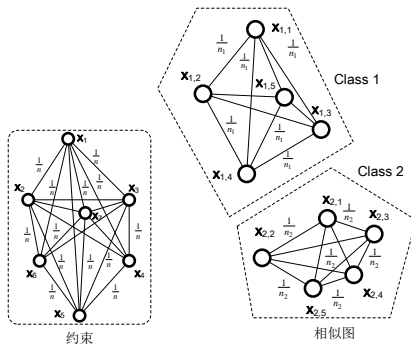
$$\mathbf{D}_{\text{LDA}} = \text{diag}(d_i) = \mathbf{I}$$

可见矩阵 \mathbf{L}_{LDA} 为Laplacian矩阵：

$$\mathbf{L}_{\text{LDA}} = \mathbf{I} - \sum_{j=1}^c \frac{1}{n_j} \mathbf{e}_j \mathbf{e}_j^t = \mathbf{D}_{\text{LDA}} - \mathbf{A}_{\text{LDA}}$$

LDA的相似图

\mathbf{A}_{LDA} 为LDA的相似矩阵，对应的相似图为分块全连接图， \mathbf{A}_{PCA} 为约束图的相似矩阵



拓扑结构与近邻图

拓扑结构和相似图

● 相似图与流形的拓扑结构


- 在谱嵌入框架下，数据集的相似图及其Laplacian矩阵是学习流形拓扑结构的重要手段
- 相似图是否能够描述流形的拓扑结构？
- 借助相似图的流形学习方法，拓扑学的理论依据是什么？

单纯形与单纯复形

● 单纯形(Simplex)

单纯形是对三角形、四面体的泛化，也称为超四面体；一个 k 维单纯形(k -simplex)由 $k + 1$ 个顶点(0-face)， $\frac{k(k+1)}{2}$ 个边(1-face)，以及一系列 $\binom{k+1}{i+1}$ 个 i -face 构成

给定空间中的 $k + 1$ 个点 $[x_0, \dots, x_k]$ ，包含这些点的最小凸集即为一个 k 维单纯形




单纯形与单纯复形

● 单纯复形(Simplicial Complex)

单纯复形是若干个单纯形构成的集合，需要满足：


1. 集合中每个单纯形的face都是集合的元素
2. 任意两个单纯形的交，都是两个单纯形的face




度量空间中的单纯复形

● Cech complex

令 (X, d) 是度量空间, $B(x, \alpha)$ 是以 $x \in X$ 为中心, $\alpha \geq 0$ 为半径的球形邻域; 点集 $D \subset X$ 上的Cech复形 $\text{Cech}_\alpha(D)$ 定义为单纯形 $[x_0, \dots, x_k]$ 的集合, 单纯形所有顶点上的 $k+1$ 个 $B(x_i, \alpha)$ 的交集非空



Cech complex





Vietoris-Rips complex

度量空间中的单纯复形

● 单纯复形与相似图

- 样本集的相似图可以看做是单纯复形的简化，只包含了其中的0-simplex和1-simplex
- Cech复形与数据分布的流形是否具有拓扑一致性？
- 如何设置适合的邻域半径 α ，避免相似图的断裂、不连续？



流形的拓扑一致性

● Cech复形与点集

作为Nerve theorem的推论，如果 D 是欧氏空间 R^d 中的点集，
则Cech复形 $\text{Cech}_\alpha(D)$ 与 $\bigcup_{\mathbf{x} \in D} B(\mathbf{x}, \alpha)$ 是同伦等价的


● 同伦(Homotopic)与同胚(Homeomorphic)

- 两个拓扑空间是同胚的，可以认为在拓扑意义下是相同的空间，具有共同的拓扑属性
- 同伦的两个拓扑空间不一定同胚，但也会具有一些相同的拓扑不变量

同伦映射

映射的同伦

令 f, g 是由空间 X 到 Y 的映射，如果有连续映射 $H : X \times I \rightarrow Y$ ，使得 $\forall x \in X, H(x, 0) = f(x), H(x, 1) = g(x)$ ，则称 f 与 g 是同伦映射，记为 $f \simeq g : X \rightarrow Y$



$H(x, t)$ 将区间 $I = [0, 1]$ 映射为了 Y 中的一条道路

同伦空间

• 空间的同伦等价

令 X 和 Y 为拓扑空间，如果有连续映射 $f : X \rightarrow Y$ 和 $g : Y \rightarrow X$ ，使得：

$$g \circ f \simeq id_X : X \rightarrow X, \quad f \circ g \simeq id_Y : Y \rightarrow Y$$

则称 X 和 Y 是同伦等价的

• 同伦与同胚

- 上述的两个复合映射只要求同伦于 X 和 Y 空间中的恒等映射 id_X, id_Y ，而不是相等
- 两个空间同胚等价必然是同伦等价，因为可以用同胚映射 f 和 f^{-1} 作为 f 和 g
- 同伦不一定同胚，映射 f 和 g 不一定是一一映射

同伦/非同胚的空间

- $R^1 \simeq R^2$

令 $f: R^2 \rightarrow R^1$ 为 $f(x, y) = x$, $g: R^1 \rightarrow R^2$ 为 $g(x) = (x, 0)$, 易见 $f \circ g = id_{R^1}$, 下面证明 $g \circ f \simeq id_{R^2}$

构造映射 $H: R^2 \times I \rightarrow R^2$:

$$H(x, y, t) = (x, ty) \implies H(x, y, 0) = (x, 0), H(x, y, 1) = (x, y)$$

有:

$$[g \circ f](x, y) = g(x) = (x, 0) = H(x, y, 0)$$



$$id_{R^2}(x, y) = (x, y) = H(x, y, 1)$$

H 为连续映射, 因此有 $g \circ f = id_{R^2}$

k -近邻相似图

• ϵ -近邻相似图



- ϵ -近邻相似图是对 Cech_α 复形的近似
- 当样本集 D 均匀抽样于流形时, $\bigcup_{\mathbf{x} \in D} B(\mathbf{x}, \alpha)$ 可以很好地描述流形的拓扑特性
- 当样本集的分布不均匀时, 很难选择合适的半径 α , 容易造成相似图的断裂



k -近邻相似图

• k -近邻相似图

- 流形上每一点的局部黎曼度量是不同的，相同半径的局部球形区域“大小”是不同的
- 复形是单纯形的集合，以模糊集合代替确定性集合，每条边(1-simplex)上的权重相当于其属于复形的隶属度



流形上的拉普拉斯算子

欧氏空间中的拉普拉斯算子

● 欧氏空间中的梯度算子

- 令 $f(\mathbf{x})$ 是 R^d 空间中的可微函数，梯度算子定义为：

$$\nabla f(\mathbf{x}) = \begin{pmatrix} \partial f / \partial x_1 \\ \vdots \\ \partial f / \partial x_d \end{pmatrix}$$

- 梯度算子 ∇ 将函数(标量场)映射为了矢量(矢量场)
- 梯度 $\nabla f(\mathbf{x})$ 的方向是函数方向导数最大值的方向，长度是该方向上函数的变化率
- 有时也可以将梯度算子记为一种矢量形式：

$$\nabla = \begin{pmatrix} \partial / \partial x_1 \\ \vdots \\ \partial / \partial x_d \end{pmatrix}$$

欧氏空间中的拉普拉斯算子

● 欧氏空间中的散度

- 令 \mathbf{F} 是 R^d 空间中矢量场，闭合曲面 S 内部的体积为 V
- 矢量场在闭合曲面的通量(通过闭合曲面的净流出量):

$$\Phi = \oint_S \langle \mathbf{F}, d\mathbf{S} \rangle$$

其中， $d\mathbf{S}$ 为法矢量面元

- 矢量场 \mathbf{F} 在点 \mathbf{x} 的散度定义为极限:

$$\operatorname{div} \mathbf{F}(\mathbf{x}) = \lim_{V \rightarrow 0} \frac{1}{V} \oint_S \langle \mathbf{F}, d\mathbf{S} \rangle$$

- 矢量场的散度可以表示为坐标形式:

$$\operatorname{div} \mathbf{F} = \langle \nabla, \mathbf{F} \rangle = \sum_{i=1}^d \frac{\partial F_i}{\partial x_i}$$

欧氏空间中的拉普拉斯算子

- 欧氏空间中的拉普拉斯算子

- 令 $f(\mathbf{x})$ 是定义在开集 $\Omega \in R^d$ 上的二次可微函数
- 拉普拉斯算子 $\Delta : C(\Omega) \rightarrow C(\Omega)$ ，是一个由标量场到标量场的映射
- 拉普拉斯算子作用于函数 $f(\mathbf{x})$ ，定义为函数梯度场的散度：

$$\Delta f(\mathbf{x}) = \operatorname{div}(\nabla f(\mathbf{x})) = \langle \nabla, \nabla f(\mathbf{x}) \rangle = \sum_{i=1}^d \frac{\partial^2 f(\mathbf{x})}{\partial x_i^2}$$

流形上的拉普拉斯算子

● 流形的切空间

- 光滑流形 \mathcal{M} 在点 $\mathbf{p} \in \mathcal{M}$ 的切向量 $\mathbf{v} : C_{\mathbf{p}}^{\infty} \rightarrow R$, 为满足下列两个条件的映射

1. $\mathbf{v}(f + \lambda g) = \mathbf{v}(f) + \lambda \mathbf{v}(g), \quad \forall f, g \in C_{\mathbf{p}}^{\infty}, \forall \lambda \in R$

2. $\mathbf{v}(fg) = \mathbf{v}(f)g(p) + f(p)\mathbf{v}(g), \quad \forall f, g \in C_{\mathbf{p}}^{\infty}$

其中, $C_{\mathbf{p}}^{\infty}$ 表示在 \mathbf{p} 点光滑函数的集合

- 点 \mathbf{p} 处所有切向量的集合 $T_{\mathbf{p}}\mathcal{M}$, 称为 \mathcal{M} 在点 \mathbf{p} 的切空间

流形上的拉普拉斯算子

● 切空间的基

令 $(U, \varphi; \{x_1, \dots, x_m\})$ 是流形 \mathcal{M} 在 \mathbf{p} 点的一个局部坐标系，沿着第 i 条坐标曲线的切向量记为 $\left. \frac{\partial}{\partial x_i} \right|_{\mathbf{p}}$ ；可以证明，集合

$$\left\{ \left. \frac{\partial}{\partial x_i} \right|_{\mathbf{p}}, 1 \leq i \leq m \right\}$$

构成了切空间 $T_{\mathbf{p}}\mathcal{M}$ 的一组基

流形上的拉普拉斯算子

● 光滑切向量场

- 流形 \mathcal{M} 上的切向量场 $\mathbf{F} : \mathcal{M} \rightarrow T\mathcal{M}$, 其中

$$T\mathcal{M} = \bigcup_{\mathbf{p} \in \mathcal{M}} T_{\mathbf{p}}\mathcal{M}$$

- 切向量场 \mathbf{F} 在 \mathcal{M} 的每一点 \mathbf{p} 处指定了一个切向量 $\mathbf{F}(\mathbf{p})$
- 切向量场可以用切空间的基来表示:

$$\mathbf{F}(\mathbf{p}) = \sum_{i=1}^m F_i(\mathbf{p}) \left. \frac{\partial}{\partial x_i} \right|_{\mathbf{p}}$$

- 如果 $F_i(\mathbf{p})$ 均为光滑函数, 则称 \mathbf{F} 为 \mathcal{M} 上的光滑切向量场, \mathcal{M} 上光滑切向量场的集合记为 $\mathfrak{X}(\mathcal{M})$

流形上的拉普拉斯算子

- 切空间中矢量的内积

流形 \mathcal{M} 在点 p 处局部坐标系下，黎曼度量 G 的元素：

$$g_{ij} = \left\langle \frac{\partial}{\partial x_i}, \frac{\partial}{\partial x_j} \right\rangle, \quad i, j = 1, \dots, m$$

切空间 $T_p\mathcal{M}$ 中的两个矢量：

$$\mathbf{v} = v_1 \frac{\partial}{\partial x_1} + \dots + v_m \frac{\partial}{\partial x_m}$$

$$\mathbf{u} = u_1 \frac{\partial}{\partial x_1} + \dots + u_m \frac{\partial}{\partial x_m}$$

两个矢量之间的内积：

$$\langle \mathbf{v}, \mathbf{u} \rangle = \sum_{i=1}^m \sum_{j=1}^m g_{ij} v_i u_j$$

流形上的拉普拉斯算子

● 流形上的梯度算子

- 黎曼流形 (\mathcal{M}, G) 上的梯度算子 $\nabla : C^\infty(\mathcal{M}) \rightarrow \mathfrak{X}(\mathcal{M})$, 将流形上的标量场映射为切向量场
- 令 $f \in C^\infty(\mathcal{M})$ 是流形 \mathcal{M} 上的可微函数, 在局部坐标系下, 函数的梯度可以表示为:

$$\begin{aligned}\nabla f &= \left(\sum_{i=1}^m g^{i1} \frac{\partial f}{\partial x_i} \right) \frac{\partial}{\partial x_1} + \cdots + \left(\sum_{i=1}^m g^{im} \frac{\partial f}{\partial x_i} \right) \frac{\partial}{\partial x_m} \\ &= \sum_{j=1}^m \left(\sum_{i=1}^m g^{ij} \frac{\partial f}{\partial x_i} \right) \frac{\partial}{\partial x_j}\end{aligned}$$

其中, g^{ij} 是黎曼度量 G 对应矩阵的逆矩阵 G^{-1} 的元素

流形上的拉普拉斯算子

● 流形上的散度算子

- 黎曼流形 (\mathcal{M}, G) 上的散度算子 $\text{div} : \mathfrak{X}(\mathcal{M}) \rightarrow C^\infty(\mathcal{M})$, 将流形上的切向量场映射为标量场
- 令 $\mathbf{F} \in \mathfrak{X}(\mathcal{M})$ 是流形 \mathcal{M} 上的切向量场, 在局部坐标系下, 切向量场的散度可以表示为:

$$\text{div} \mathbf{F} = \langle \nabla, \mathbf{F} \rangle = \frac{1}{\sqrt{|G|}} \sum_{i=1}^m \frac{\partial}{\partial x_i} \left(\sqrt{|G|} F_i \right)$$

其中, $|G|$ 是黎曼度量对应矩阵的行列式值

流形上的拉普拉斯算子

● 拉普拉斯-贝尔特拉米算子

- 黎曼流形 (\mathcal{M}, G) 上的算子 $\Delta : C^\infty(\mathcal{M}) \rightarrow C^\infty(\mathcal{M})$ ，将流形上的标量场映射为标量场，称为 Laplace - Beltrami 算子
- 令 $f \in C^\infty(\mathcal{M})$ 是流形 \mathcal{M} 上的光滑函数，在局部坐标系下：

$$\Delta f = \langle \nabla, \nabla f \rangle = \frac{1}{\sqrt{|G|}} \sum_{i=1}^m \frac{\partial}{\partial x_i} \left(\sqrt{|G|} \sum_{j=1}^m g^{ij} \frac{\partial f}{\partial x_j} \right)$$

Stokes定理

• Stokes' Theorem

负散度算子 $-\text{div}$ 与梯度算子 ∇ 为伴随算子(formally adjoint operators), 满足:

$$\int_{\mathcal{M}} \langle \mathbf{F}, \nabla f \rangle d\mathbf{x} = - \int_{\mathcal{M}} \text{div} \mathbf{F} \cdot f d\mathbf{x}$$

当切向量场 $\mathbf{F} = \nabla f$ 时, 有:

$$\int_{\mathcal{M}} \|\nabla f\|^2 d\mathbf{x} = \int_{\mathcal{M}} \langle \nabla f, \nabla f \rangle d\mathbf{x} = - \int_{\mathcal{M}} \text{div}(\nabla f) \cdot f d\mathbf{x} = - \int_{\mathcal{M}} \Delta f \cdot f d\mathbf{x}$$

流形的低维嵌入

● 流形的低维映射

令 \mathcal{M} 是嵌入在 R^d 空间的 m 维黎曼流形，希望寻找流形到1维欧氏空间的映射 $f: \mathcal{M} \rightarrow R$ ，使得流形上临近的点 \mathbf{x}, \mathbf{z} ，映射之后的距离尽可能地小

上述目标同谱嵌入的框架是一致的，差别在于这里讨论的是连续的低维流形嵌入，而谱嵌入框架面对的是流形上的一个抽样数据集

流形的低维嵌入

● 映射之后的距离

令 $l = \text{dist}_{\mathcal{M}}(\mathbf{x}, \mathbf{z})$ 为两点在流形上的测地距离, $c(t)$ 为参数化的测地曲线, 则有:

$$f(\mathbf{z}) = f(\mathbf{x}) + \int_0^l df(c'(t))dt$$

其中, $df(c'(t))$ 是映射 f 沿着测地曲线切线方向的增量, 积分由测地线的一端到另一端累计函数的增量

利用Schwartz不等式和Taylor近似可以得到, 映射之后两点之间的距离:

$$|f(\mathbf{z}) - f(\mathbf{x})| \leq l \|\nabla f(\mathbf{x})\| + o(l)$$

流形的低维嵌入

• 优化低维映射

$l = \text{dist}_{\mathcal{M}}(\mathbf{x}, \mathbf{z})$ 是两点在流形上的测地距离，与映射 f 无关，因此希望映射之后两点的距离尽量小，需要最小化整个流形上每个点梯度的范数

为了避免得到 $f(\mathbf{x}) = C$ 的无意义解，需要约束函数 $f(\mathbf{x})$ 的范数：

$$\arg \min_{\|f\|^2=1} \int_{\mathcal{M}} \|\nabla f(\mathbf{x})\|^2 d\mathbf{x}$$

根据Stokes定理，得到等价的优化问题：

$$\arg \max_{\|f\|^2=1} \int_{\mathcal{M}} \Delta f(\mathbf{x}) \cdot f(\mathbf{x}) d\mathbf{x}$$

流形的低维嵌入

● 嵌入函数与拉普拉斯算子的谱

构造Lagrange函数:

$$L(f(\mathbf{x})) = \int_{\mathcal{M}} \Delta f(\mathbf{x}) \cdot f(\mathbf{x}) d\mathbf{x} - \lambda(\|f(\mathbf{x})\|^2 - 1)$$

对 $f(\mathbf{x})$ 求导, 计算极值:

$$\Delta f(\mathbf{x}) = \lambda f(\mathbf{x})$$

因此, 嵌入函数 $f(\mathbf{x})$ 为拉普拉斯算子 Δ 的特征函数

流形的低维嵌入

● 拉普拉斯算子与拉普拉斯矩阵

如果有流形 \mathcal{M} 上的有限抽样集 $\{\mathbf{x}_1, \dots, \mathbf{x}_n\}$, 可以构造近邻相似图(1-simplicial complex)近似流形的拓扑结构; 函数 $f(\mathbf{x})$ 映射之后的函数值为 $\{f_1, \dots, f_n\}$

沿着近邻 \mathbf{x}_i 到 \mathbf{x}_j 测地线 c_{ij} 方向上函数的变化率:

$$\nabla_{c_{ij}} f(\mathbf{x}_i) \approx \frac{f_j - f_i}{\|\mathbf{x}_i - \mathbf{x}_j\|_{\mathcal{M}}}$$

如果令 $W_{ij} \approx \frac{1}{\|\mathbf{x}_i - \mathbf{x}_j\|_{\mathcal{M}}^2}$, 函数 $f(\mathbf{x})$ 在 \mathbf{x}_i 点梯度长度的平方, 可以用各个方向上函数变化率平方之和来近似:

$$\|\nabla f(\mathbf{x}_i)\|^2 \approx \sum_{\mathbf{x}_j \in N(\mathbf{x}_i)} (f_i - f_j)^2 W_{ij}$$

流形的低维嵌入

● 拉普拉斯算子与拉普拉斯矩阵

用抽样集上梯度长度平方之和近似在整个流形上的积分：

$$\int_{\mathcal{M}} \|\nabla f(\mathbf{x})\|^2 d\mathbf{x} \approx \sum_{i,j} (f_i - f_j)^2 W_{ij} = \mathbf{f}^t L \mathbf{f}$$

比较Stokes公式：

$$\int_{\mathcal{M}} \|\nabla f\|^2 d\mathbf{x} = \int_{\mathcal{M}} f \cdot \Delta f d\mathbf{x}$$

可以看出，相似图的拉普拉斯矩阵 L 是流形 \mathcal{M} 上拉普拉斯-贝尔特拉米算子 Δ 的近似